

---

COMPILANDO CONOCIMIENTO

# Probabilidad y Estadística

MATEMÁTICAS ESTADÍSTICAS

Oscar Andrés Rosas Hernandez

Febrero 2018

# Índice general

<b>I</b>	<b>Probabilidad Clásica</b>	<b>4</b>
<b>1.</b>	<b>Introducción</b>	<b>5</b>
1.1.	Notación . . . . .	6
1.1.1.	Experimento $\varepsilon$ . . . . .	6
1.1.2.	Espacio Muestral $S, \Omega$ . . . . .	6
1.1.3.	Evento $A$ . . . . .	6
1.2.	Probabilidad $P(A)$ . . . . .	7
1.2.1.	Consecuencias . . . . .	8
1.3.	Probabilidad Condicional . . . . .	9
1.3.1.	Regla de la Multiplicación . . . . .	9
1.4.	Eventos Independientes . . . . .	10
1.4.1.	Propiedades . . . . .	10
1.5.	Teorema de Bayes . . . . .	11
<b>2.</b>	<b>Combinatoria</b>	<b>12</b>
2.1.	Ideas Clave . . . . .	13
2.1.1.	Orden vs Sin Orden . . . . .	13
2.1.2.	Remplazar vs No Remplazar . . . . .	13
2.2.	Fórmulas . . . . .	14
2.3.	Coeficientes Binomiales . . . . .	15
2.3.1.	Interpretación . . . . .	15
2.3.2.	Propiedades . . . . .	15
2.4.	Propiedades . . . . .	16

<b>II</b>	<b>Variables Aleatorias Discretas</b>	<b>17</b>
<b>3.</b>	<b>Variables Aleatorias Discretas</b>	<b>18</b>
3.1.	Variables Aleatorias . . . . .	19
3.1.1.	Variables Aleatorias Discretas . . . . .	19
3.2.	Función Probabilidad $f_X$ . . . . .	20
3.2.1.	Definición . . . . .	20
3.2.2.	Ejemplos . . . . .	20
3.3.	Función P. Acumulada $F_X$ . . . . .	21
3.3.1.	Definición . . . . .	21
3.3.2.	Propiedades . . . . .	21
3.4.	Esperanza o Media . . . . .	22
3.4.1.	Definición . . . . .	22
3.4.2.	Propiedades . . . . .	22
3.5.	Varianza . . . . .	23
3.5.1.	Definición . . . . .	23
3.5.2.	Propiedades . . . . .	23
3.6.	Desviación Estandar . . . . .	25
3.7.	Covarianza . . . . .	26
3.7.1.	Definición . . . . .	26
3.7.2.	Propiedades . . . . .	26
3.8.	Momentos Centrales . . . . .	27
3.8.1.	Propiedades . . . . .	27
3.8.2.	Función Generadora de Momentos . . . . .	28
3.8.3.	Propiedades . . . . .	28
<b>4.</b>	<b>Distribuciones Famosas</b>	<b>29</b>
4.1.	Bernoulli . . . . .	30
4.2.	Binomial . . . . .	32
4.3.	Geométrica . . . . .	33
4.4.	Hiper-Geométrica . . . . .	37

4.4.1. Definición . . . . .	37
4.4.2. Función Probabilidad . . . . .	38
4.4.3. Función P. Acumulada . . . . .	38
4.4.4. Esperanza . . . . .	39
4.4.5. Función Generadora . . . . .	40
4.5. Poisson . . . . .	41
4.5.1. Función Probabilidad . . . . .	42
4.5.2. Función P. Acumulada . . . . .	42
4.5.3. Función Generadora . . . . .	43
4.5.4. Esperanza . . . . .	44
4.5.5. Varianza . . . . .	44
4.5.6. Relación con la Binomial . . . . .	45

# Parte I

## Probabilidad Clásica

# Capítulo 1

## Introducción

## 1.1. Notación

### 1.1.1. Experimento $\varepsilon$

Decimos que un experimento en probabilidad es cualquier proceso del cual se desconoce con determinación el resultado final.

Generalmente lo denotamos con mayúsculas.

### 1.1.2. Espacio Muestral $S, \Omega$

Un espacio muestral asociado a un experimento es el conjunto de posibles resultados al momento de realizar el experimento.

**Ejemplo:**

Por ejemplo si  $\varepsilon_1$  : Lanzar una moneda. Entonces tenemos que  $S_1 = \{ Cara, Cruz \}$

Si  $\varepsilon_2$  : Lanzar un dado. Entonces tenemos que  $S_2 = \{ 1, 2, 3, 4, 5, 6 \}$

### 1.1.3. Evento $A$

Un evento es simplemente algún subconjunto del espacio muestral.

**Ejemplo:**

Por ejemplo si  $\varepsilon_1$  : Lanzar una moneda. Entonces tenemos que un evento puede ser  $A_1 = \{ Cara \}$

Si  $\varepsilon_2$  : Lanzar un dado. Entonces tenemos que un evento puede ser  $A_2 = \{ 1, 2, 4 \}, A_{2.1} = \{ 5 \}$

## 1.2. Probabilidad $P(A)$

Definimos la probabilidad de un evento  $A$  como:

$$P(A) = \frac{|A|}{|S|} \quad \text{Recuerda que } A \text{ es un evento y } S \text{ es espacio muestral}$$

Creo que es muy obvio por la manera en que definimos a la probabilidad de un evento es un número real entre 0 y 1.

Por lo tanto:

- **NO hay probabilidades negativas**
- **NO hay probabilidades mayores a uno**

Entonces podemos reducir el problema de encontrar la probabilidad de un evento simplemente a dos partes:

- Encontrar la cardinalidad de dicho evento
- Encontrar la cardinalidad del espacio muestral de un experimento



### 1.2.1. Consecuencias

- $P(S) = 1$
- Si  $A_1, A_2, \dots, A_n$  son eventos mutuamente excluyentes entonces:

$$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$$

- Si  $A_1, A_2, \dots$  son una colección infinita, pero contable de eventos mutuamente excluyentes entonces:

$$P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

- $P(\emptyset) = 0$
- $P(A') = 1 - P(A)$
- Si  $A \subseteq B$  entonces  $P(A) \leq P(B)$
- La probabilidad de la unión de n eventos se puede escribir de manera general como:

$$P(\cup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i) - \sum_{i < j} P(A_i A_j) + \sum_{i < j < k} P(A_i A_j A_k) + \dots + (-1)^{n+1} P(\cap_{i=1}^n A_i)$$

- Por consecuencia del caso general tenemos que:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- Por consecuencia del caso general tenemos que:

$$\begin{aligned} P(A \cup B \cup C) = & \\ & P(A) + P(B) + P(C) \\ & - (P(A \cap B) + P(A \cap C) + P(B \cap C)) \\ & + P(A \cap B \cap C) \end{aligned}$$

## 1.3. Probabilidad Condicional

La probabilidad de que ocurra el Evento  $A$  conociendo que ya paso el Evento  $B$  se denota y define como:

$$P(A \mid B) := \frac{P(A \cap B)}{P(B)} = \frac{|A \cap B|}{|B|}$$

Nota que para que todo esto tenga sentido  $P(A) \neq 0$

Podemos notar entonces que el evento  $B$  tiene muchas interpretaciones como:

- La condición que ya esta dada
- Evento que se sabe que ya ocurrió o que es seguro que ocurra
- Espacio Muestral Reducido

### 1.3.1. Regla de la Multiplicación

Nota que  $P(A \cap B)$  se puede ver como:

$$P(A \cap B) = P(A|B)P(B) = P(B|A)P(A)$$

Podemos entonces redefinir la propabilidad condicional como:

$$\begin{aligned}
 P(A|B) &= \frac{P(A \cap B)}{P(B)} && \text{Por definición} \\
 &= \frac{P(B \mid A)P(A)}{P(B)} && \text{Por regla de multiplicación en el numerador} \\
 &= \frac{P(B \mid A)P(A)}{P((B \cap A) \cup (B \cap A'))} && \text{Unión de eventos disjuntos} \\
 &= \frac{P(B \mid A)P(A)}{P(B \cap A) + P(B \cap A')} && \text{Aplicando regla de la multiplicación a cada uno} \\
 &= \frac{P(B \mid A)P(A)}{P(B|A)P(A) + P(B|A')P(A')}
 \end{aligned}$$

## 1.4. Eventos Independientes

Dados 2 eventos que  $A, B$  son Independientes si y solo si  $P(A) = P(A|B)$  y se escribe:  $A \perp B$ .

### 1.4.1. Propiedades

- Si  $A \perp B$  entonces  $P(A \cap B) = P(A)P(B)$

**Demostración:**

Si  $A \perp B$  entonces  $P(B) = P(B|A)$ , por lo tanto  $P(B) = \frac{P(B \cap A)}{P(A)}$

Y solo despejas

- Si  $A \perp B$  entonces  $A' \perp B'$

**Demostración:**

Esta es clave:

$$\begin{aligned} P(A' \cap B') &= P((A \cup B)') \\ &= 1 - [P(A) + P(B) + P(A \cap B)] \\ &= 1 - [P(A) + P(B) + P(A \cap B)] \\ &= (1 - P(A))(1 - P(B)) \\ &= P(A')P(B') \end{aligned}$$

- Si  $A \perp B$  entonces  $P(A \cap B) \neq 0$  o la contrapositiva que dice que si son disjuntos entonces no son independientes

## 1.5. Teorema de Bayes

Considera un conjunto de eventos  $\{A_1, \dots, A_n\}$  mutuamente exclusivos y tales que  $\cup_{i=1}^n A_i = S$ , es decir son particiones de  $S$ .

Entonces podemos escribir la probabilidad de un evento  $B$  como:

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

Gracias a esto podemos decir que:

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B|A_i)P(A_i)}{\sum_{i=1}^n P(A_i)P(B|A_i)} \end{aligned}$$

## Capítulo 2

# Combinatoria

## 2.1. Ideas Clave

### 2.1.1. Orden vs Sin Orden

En las muestras que estan ordenadas entonces el orden de los elementos importa por ejemplo en los dígitos de un teléfono o en las letras de una palabra.

En las muestras que no estan ordenadas el orden es irrelevante, por ejemplo en los elementos de un conjunto.

### 2.1.2. Remplazar vs No Remplazar

Las muestras con remplazo entonces estan permitidas, por ejemplo los números de la licencia.

Cuando la repetición no esta permitida, por ejemplo en un conjunto de números de lotería

## 2.2. Fórmulas

- Número de **permutaciones** de un conjunto de  $n$  objetos

$$n! \quad (2.1)$$

- Número de **muestras ordenadas** de tamaño  $r$  **con remplazo** de un conjunto de  $n$  objetos

$$n^r \quad (2.2)$$

- Número de **muestras ordenadas** de tamaño  $r$  **sin remplazo** de un conjunto de  $n$  objetos

$${}_nP_r = \frac{n!}{(n-r)!} = (n)(n-1)(n-2) \dots (n-r+1) \quad (2.3)$$

- Número de **muestras no ordenadas** de tamaño  $r$  **sin remplazo** de un conjunto de  $n$  objetos

Esto es lo mismo que el número de subconjuntos de cardinalidad  $r$  de un conjunto de  $n$  elementos

$$\binom{n}{r} = {}_nC_r = \frac{{}_nP_r}{r!} = \frac{n!}{r!(n-r)!} = \frac{(n)(n-1)(n-2) \dots (n-r+1)}{r!} \quad (2.4)$$

- Número de subconjuntos de un conjunto de  $n$  elementos:

$$2^n \quad (2.5)$$

## 2.3. Coeficientes Binomiales

### 2.3.1. Interpretación

Podemos interpretarlos de muchas maneras, algunas son:

- El número de formas de seleccionar  $k$  objetos de un conjunto de  $n$  elementos.
- El número de subconjuntos de elementos  $k$  en un conjunto de  $n$  elementos.

### 2.3.2. Propiedades

- Número de **permutaciones** de un conjunto de  $n$  objetos

$$\binom{n}{r} = \frac{n!}{k!(n-k)!} \quad \text{donde } n \in \mathbb{N} \text{ y } k \in \{1, \dots, n\} \quad (2.6)$$

$$= \frac{(n)(n-1)(n-2) \dots (n-k+1)}{k!} \quad (2.7)$$

- Número de **permutaciones** de un conjunto de  $n$  objetos

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \quad (2.8)$$

- Propiedades Simétricas

$$\binom{n}{k} = \binom{n}{n-k} \quad (2.9)$$

- Casos Especiales

$$\binom{n}{0} = \binom{n}{n} = 1 \quad \binom{n}{1} = \binom{n}{n-1} = n \quad (2.10)$$

- Teorema del Binomio

$$(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k} \quad (2.11)$$

- Teorema del Binomio (Caso Especial)

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = 1 \quad (2.12)$$



## 2.4. Propiedades

- Las formas de permutar  $n$  elementos en un círculo es  $(n - 1)!$

## Parte II

### Variables Aleatorias Discretas

## Capítulo 3

### Variables Aleatorias Discretas

### 3.1. Variables Aleatorias

Una variable aleatoria es una función que asigna a cada elemento  $E_i \in S$  en el espacio muestral a un número real  $X(E_i) \in \mathbb{R}$ , es decir, en español, lo que hace es que es una función que nos da información de una característica de cada elemento del espacio muestral.

Esta se denota con mayúsculas y no es un número, es una función. Para poner a un valor posible de una variable aleatoria lo denotamos con minúsculas.

#### 3.1.1. Variables Aleatorias Discretas

Las variables aleatorias cuyo conjunto de valores posibles es finito o infinito contable entonces decimos que es una variable aleatoria discreta.

**Ejemplo:**

Por ejemplo considera que vas a lanzar 3 monedas, entonces tenemos que:

$$S = \{ ccc, ccx, cxc, xcc, xxc, xcx, cxx, xxx \}$$

Entonces podemos tener una variable aleatoria como:

Sea  $X$  = Número de caras en 3 lanzamientos.

Entonces podemos decir que:

$$\begin{aligned} X(ccc) &= 3 \\ X(ccx) &= 2 \\ X(cxc) &= 2 \\ X(xcc) &= 2 \\ X(xxc) &= 1 \\ X(xcx) &= 1 \\ X(cxx) &= 1 \\ X(xxx) &= 0 \end{aligned}$$

Por lo tanto los vales posibles son 0, 1, 2, 3.

## 3.2. Función Probabilidad $f_X$

### 3.2.1. Definición

También se le conoce como función de probabilidad puntual. Es una función que toma todos los posibles valores una variable aleatoria y nos regresa un número real entre el 0 y el 1 dado por la probabilidad de el valor de la variable aleatoria sea  $x$ . Es decir:

$$f_X(x) = P(X = x)$$

Es una función de probabilidad, es decir tiene que cumplir que la suma de todos los posibles valores de la variable aleatoria den uno.

Más formalmente tenemos que la función probabilidad es aquella función que cumple que:

- $\forall a \in \mathbb{R} f_X(a) \geq 0$
- $\{ x \mid f_X(x) \neq 0 \}$  es un conjunto finito o numerable
- $\sum_x f_X(x) = 1$

### 3.2.2. Ejemplos

#### Ejemplo:

Por ejemplo podemos definir la probabilidad del ejemplo pasado podemos definir la función

$$f_X(x) = \binom{3}{x} \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{3-x} \text{ para } x \in \{ 0, 1, 2, 3 \}$$

Entonces tenemos que:

- La probabilidad de que  $X = 0$  (caigan 0 caras) es  $\frac{1}{8}$
- La probabilidad de que  $X = 1$  (caigan 1 caras) es  $\frac{3}{8}$
- La probabilidad de que  $X = 2$  (caigan 2 caras) es  $\frac{3}{8}$
- La probabilidad de que  $X = 3$  (caigan 3 caras) es  $\frac{1}{8}$

### 3.3. Función P. Acumulada $F_X$

#### 3.3.1. Definición

Describimos a la función de probabilidad acumulada como:

$$\overline{F}_X(x) = \sum_{i < x} f_X(i)$$

#### 3.3.2. Propiedades

Podemos ver a la acumulada como una función fundamental, tal que podemos escribir a todas las demás:

- $P(X < x) = \overline{F}_X(x - 1)$
- $P(X \leq x) = \overline{F}_X(x)$
- $P(X > x) = 1 - \overline{F}_X(x)$
- $P(X \geq x) = 1 - \overline{F}_X(x - 1)$
- $P(a \leq X \leq b) = \overline{F}_X(b) - \overline{F}_X(a - 1)$
- $P(a < X \leq b) = \overline{F}_X(b) - \overline{F}_X(a)$
- $P(a \leq X < b) = \overline{F}_X(b - 1) - \overline{F}_X(a)$
- $P(a < X < b) = \overline{F}_X(b - 1) - \overline{F}_X(a - 1)$

## 3.4. Esperanza o Media

### 3.4.1. Definición

Decimos que el valor esperado, esperanza ó media de la variable  $X$  se define como:

$$\mu_X = E(X) = \sum_x x f_X(x) = \sum_x x P(X = x)$$

Representa un promedio ponderado de los valores posibles de la variable basado en sus probabilidades.

Es decir, si se repitiera el experimento muchísimas veces el promedio de los resultados se iría aproximando a la media.

### 3.4.2. Propiedades

- Si  $X$  puede tomar un número infinito de valores entonces la esperanza de  $X$  existe si y solo si  $\sum_x |x| f_X(x) < \infty$
- Podemos dar una definición al evaluar la media en  $E(g(x)) = \sum_x g(x) f_X(x)$
- Es un Operador Lineal, es decir:  
$$E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$$
- Si  $X, Y$  son independientes entonces  $E(XY) = E(X) + E(Y)$
- Si  $a$  es una constante, entonces:  $E(a) = a$

## 3.5. Varianza

### 3.5.1. Definición

Decimos que la varianza de la variable  $X$  con  $f_X(x)$  se define como:

$$v(X) = E((X - \mu)^2)$$

Podemos decir por su misma definición que la varianza siempre es positiva.

Es decir, este valor nos indica que tan lejos estan en promedio los valores de su misma media, es decir, que tan dispersa o concentrada esta la distribución de los datos.

### 3.5.2. Propiedades

- $v(X) = E(X^2) - (E(X))^2$

**Demostración:**

Esto esta demasiado sencillo:

$$\begin{aligned} v(X) &= E((X - \mu)^2) \\ &= E(X^2 - 2X\mu + \mu^2) \\ &= E(X^2) - E(2X\mu) + E(\mu^2) \\ &= E(X^2) - 2\mu E(X) + E(\mu^2) \\ &= E(X^2) - 2\mu^2 + \mu^2 \\ &= E(X^2) - \mu^2 \end{aligned}$$

- $V(a) = 0$

**Demostración:**

Sea  $a = g(X)$ , entonces su  $\mu = a$ , por lo tanto

$$\begin{aligned} V(a) &= E(a - a)^2 \\ &= E(0)^2 \\ &= 0 \end{aligned}$$

- $v(aX) = a^2v(X)$

**Demostración:**

$$\begin{aligned} V(aX) &= E(aX^2) - E^2(aX) \\ &= a^2E(X^2) - a^2E^2(X) \\ &= a^2[E(X^2) - E^2(X)] \\ &= a^2[v(X)] \end{aligned}$$



- $v(X + Y) = v(X) + v(Y) + 2Cov(X, Y)$
- $v(X - Y) = v(X) + v(Y) - 2Cov(X, Y)$
- Si  $X$  y  $Y$  son independientes, entonces  $v(X + Y) = v(X) + v(Y)$
- En general si  $X_1, X_2, \dots, X_n$  son variables aleatorias, entonces tenemos que:

$$v\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n v(X_i) + 2 \sum_{i < j} Cov(X_i, X_j)$$

## 3.6. Desviación Estándar

Decimos que la varianza de la variable  $X$  con  $f_X(x)$  se define como:

$$\sigma(X) = \sqrt{v(X)}$$

Podemos decir por su misma definición que la varianza siempre es positiva.

Es decir, este valor nos indica que tan lejos estan en promedio los valores de su misma media, es decir, que tan dispersa o concentrada esta la distribución de los datos.

## 3.7. Covarianza

### 3.7.1. Definición

Sea  $X, Y$  dos variables independientes, entonces definimos a la covarianza como:

$$\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y))$$

Es una manera de medir la dispersión conjunta de ambas variables.

### 3.7.2. Propiedades

- $\text{Cov}(X, Y) = E(XY) - \mu_X\mu_Y$

**Demostración:**

Podemos demostrar esto, bien facil:

$$\begin{aligned} \text{Cov}(X, Y) &= E((X - \mu_X)(Y - \mu_Y)) \\ &= E(XY - X\mu_Y - \mu_X Y + \mu_X\mu_Y) \\ &= E(XY) - E(X\mu_Y) - E(\mu_X Y) + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y E(X) - \mu_X E(Y) + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y\mu_X - \mu_X\mu_Y + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y \\ &= E(XY) - \mu_Y\mu_X \end{aligned}$$

- La covarianza de 2 variables independientes es cero

**Demostración:**

Mira esto:

$$\begin{aligned} \text{Cov}(X, Y) &= E(XY) - \mu_Y\mu_X \\ &= E(X)E(Y) - \mu_Y\mu_X \\ &= 0 \end{aligned}$$

Si es que son independientes

Recuerda que  $E(X) = \mu_X$

## 3.8. Momentos Centrales

Si  $X$  es una variable aleatoria tal que  $E(X) = \mu_x$  entonces tenemos que:

- El  $k$ -ésimo momento central esta definida como:

$$\mu_k^c = E[(X - \mu)^k] = \sum_x (x - \mu)^k P(X = x) \quad (3.1)$$

- El  $k$ -ésimo momento alrededor del origen esta definida como:

$$\mu_k^0 = E[(X)^k] = \sum_x x^k P(X = x) \quad (3.2)$$

### 3.8.1. Propiedades

- Ya hemos trabajado con momentos, por ejemplo, la varianza la podemos definir como:  $v(X) = E(X^2) - \mu^2$  donde  $E(X^2)$  es un segundo momento central  
O bien, verla como  $v(X) = E[(X - \mu)^2]$  es decir la varianza es el segundo momento central.

### 3.8.2. Función Generadora de Momentos

La podemos definir como:

$$\Psi_X(t) = E(e^{tX}) = \sum_x e^{tx} P(X = x)$$

Solemos decir que la k-ésima derivada de la función generadora de momentos evaluada en  $t = 0$  da como resultado el k-ésimo momento central al origen

Es decir, siguen el siguiente patrón:

- $\Psi'_X(t = 0) = E(X)$
- $\Psi''_X(t = 0) = E(X^2)$
- $\Psi'''_X(t = 0) = E(X^3)$
- $\Psi^{(n)}_X(t = 0) = E(X^n)$

### 3.8.3. Propiedades

- Si  $Y = aX + b$  entonces tenemos que:

$$\Psi_Y(t) = e^{bt} \Psi_X(at)$$

- Nota que  $\Psi_x(a) = E(e^{aX})$

- $\Psi_X(t = 0) = \mu_k$

- $\Psi_X(t = 0) = E(X)$

- Nota que si tuvieramos un montón de variables aleatorias  $X_1, X_2, X_3, \dots, X_n$  Y decimos que  $Y = \sum_{i=1}^n X_i$

Entonces tenemos que  $\Psi_Y(t) = \prod_{i=1}^n \Psi_{X_i}(t)$

## Capítulo 4

### Distribuciones Famosas

## 4.1. Bernoulli

Suponte un experimento en el que solo tienes dos salidas, 0, 1, suponte que la probabilidad de que salga 0 es  $q$  y la que salga 1 es  $p$ .

Ahora veamos algunas características:

- **Función Probabilidad**

Esta es fácil  $f_X(x) = p^x q^{1-x}$

- **Esperanza de X**

Nota que por definición tenemos que:

$$\begin{aligned}\mu_X &= \sum_x xP(X=x) \\ &= 0(q) + 1(p) \\ &= p\end{aligned}$$

- **Varianza**

Por definición tenemos que:

$$\begin{aligned}v(X) &= E(x^2) - \mu^2 \\ &= E(x^2) - p^2 \\ &= \sum_x x^2 P(X=x) - p^2 \\ &= 0(q) + 1(p) - p^2 \\ &= p - p^2 \\ &= p(1-p) \\ &= pq\end{aligned}$$

- **Acumulada**

Por definición tenemos que:

$$F_X(x) = \begin{cases} 0 & x < 0 \\ q & 0 \leq x < 1 \\ p & 1 \leq x \end{cases}$$

- **Función Genera de Momentos**

Por definición tenemos que:

$$\begin{aligned}\Psi(t) &= E(e^t X) \\ &= \sum_x e^t x P(X = x) \\ &= e^{0t}(q) + e^{1t}(p) \\ &= (q) + e^t(p)\end{aligned}$$



## 4.2. Binomial

Es un experimento binomial que consiste en  $n$  ensayos Bernoulli independientes, con una probabilidad de éxito individual constante.

La variable discreta es el número de éxitos de los experimentos individuales donde sus posibles valores fueron  $X = \{0, 1, \dots, n\}$ .

Observa que la variable aleatoria se puede ver como la suma de Bernoullis independientes.

Ahora veamos algunas características:

- **Función Probabilidad**

Esta es fácil  $f_X(x) = \binom{n}{x} p^x q^{n-x}$

¿Porque? Porque estamos hablando de eventos independientes por lo tanto su probabilidad conjunta es el producto de las individuales, y literalmente estamos usando la definición de combinación.

- **Función Acumulada**

Esta es fácil  $F_X(x) = \sum_{i=0}^x \binom{n}{i} p^i q^{n-i}$

- **Esperanza de X**

Podemos usar que la variable aleatoria se puede ver como la suma de Bernoullis independientes.

Es decir  $Y = \sum_i x_i$

$$\begin{aligned} \mu_X &= E(Y) \\ &= E\left(\sum_i x_i\right) \\ &= \sum_i E(x_i) \\ &= np \end{aligned}$$

- **Varianza**

Por definición tenemos que:

$$v(X) = npq$$

- **Función Genera de Momentos**

Por definición tenemos que:

$$\Psi(t) = (q + e^t p)^n$$

### 4.3. Geométrica

Supón que se repiten de manera independiente ensayos Bernoulli con una probabilidad de éxito constante de  $p$  hasta obtener el primer éxito.

La variable discreta es el número de experimentos hasta un primer éxito donde sus posibles valores fueron  $X = \{0, 1, \dots\}$ .

Observa que la variable aleatoria se puede ver como la suma de Bernoullis independientes.

Ahora veamos algunas características:

■ **Función Probabilidad**

Esta es fácil  $f_X(x) = q^{x-1}p$

Es decir, es la probabilidad de que todos los anteriores sean fracasos y el actual sea el éxito.

■ **Función Acumulada**

$F_X(x) = 1 - q^x$

Esta es fácil:

$$\begin{aligned} F_X(x) &= \sum_{i=1}^x pq^{i-1} \\ &= p \sum_{i=0}^{x-1} q^i \\ &= p \frac{1 - q^x}{1 - q} \\ &= p \frac{1 - q^x}{p} \\ &= 1 - q^x \end{aligned}$$

■ **Esperanza de X**

Esta es muy famosa:  $E(X) = \frac{1}{p}$

**Demostración:**

$$\begin{aligned}
 E(X) &= \sum_{x=1}^{\infty} xP(X=x) \\
 &= \sum_{x=1}^{\infty} xq^{x-1}p \\
 &= p \sum_{x=1}^{\infty} xq^{x-1} \\
 &= p \frac{d}{dx} \sum_{x=1}^{\infty} xq^{x-1} \\
 &= p \frac{d}{dx} \sum_{x=1}^{\infty} q^x \\
 &= p \frac{d}{dx} \frac{1}{1-q} \\
 &= p \frac{1}{(1-q)^2} \\
 &= p \frac{1}{p^2} \\
 &= \frac{1}{p}
 \end{aligned}$$

■ **Varianza**

$$v(X) = \frac{1-p}{p^2}$$

$$\begin{aligned}
 v(X) &= E(X^2) - \mu^2 \\
 &= E(X^2) - \frac{1}{p^2} \\
 &= \sum_{x=1}^{\infty} x^2 P(X=x) - \frac{1}{p^2} \\
 &= \sum_{x=1}^{\infty} x^2 p q^{x-1} - \frac{1}{p^2} \\
 &= p \sum_{x=1}^{\infty} x^2 q^{x-1} - \frac{1}{p^2} \\
 &= p \frac{1+q}{(1-q)^3} - \frac{1}{p^2} \\
 &= \frac{1+q}{p^2} - \frac{1}{p^2} \\
 &= \frac{q}{p^2} \\
 &= \frac{1-p}{p^2}
 \end{aligned}$$

■ **Función Genera de Momentos**

Por definición tenemos que:

$$\begin{aligned}
 \Psi(t) &= E(e^{tX}) \\
 \Psi(t) &= \sum_{x=1}^{\infty} e^{tx} q^{x-1} p \\
 \Psi(t) &= p \sum_{x=1}^{\infty} e^{tx} q^{x-1} \\
 \Psi(t) &= p \sum_{x=1}^{\infty} e^{tx} q^{x-1} \\
 \Psi(t) &= p e^t \sum_{x=1}^{\infty} (q e^t)^{x-1} \\
 \Psi(t) &= p e^t \frac{1}{1 - q e^t} \\
 \Psi(t) &= \frac{p e^t}{1 - q e^t}
 \end{aligned}$$

## Propiedades

- Sea  $P(X > a) = q^a$  con  $a$  un natural positivo

**Demostración:**

$$\begin{aligned} P(Y > a) &= 1 - F_X(a) && \text{Definición de Acumulada} \\ &= 1 - (1 - q^a) && \text{Talacha} \\ &= q^a && \text{Bingo} \end{aligned}$$

- Sea  $P(X > a + b \mid X > a) = P(X > b)$  con  $a, b$  un naturales positivos

**Demostración:**

$$\begin{aligned} P(X > a + b \mid X > a) &= \frac{P(X > a + b \text{ y } X > a)}{P(X > a)} && \text{Definición de Condicional} \\ &= \frac{P(X > a + b)}{P(X > a)} && \text{Sentido común} \\ &= \frac{p^{a+b}}{p^a} && \text{Teorema pasado} \\ &= p^{(a+b)-a} && \text{Exponentes} \\ &= p^b && \text{Usando teorema pasado} \\ &= P(X > b) \end{aligned}$$

## 4.4. Hiper-Geométrica

### 4.4.1. Definición

Supongamos que tenemos una población de tamaño  $r$ , ahora esta particionado de 2 maneras, como elementos del tipo  $r_1$  o  $r_2$ .

Ahora vamos a tomar una muestra aleatoria de tamaño  $n$  sin reemplazo ni sustitución.

Ahora, solo por notación si es que  $n$ , es decir la muestra es menor que nuestra población  $r$  la llamamos muestra, pero si  $n = r$  entonces decimos que es un censo.

lem

### Variable Aleatoria

Ahora, nuestra variable aleatoria sera:

$X$  : Número de elementos del tipo  $r_1$  en una muestra aleatoria de tamaño  $n$

Ahora, los valores posibles que puede tomar es  $\max(0, n - r_2) \leq x \leq \min(r_1, n)$  Ahora, ¿Porque esos números tan feos? Por un lado tenemos que que lo peor que nos puede pasar son dos cosas, o bien su tu muestra es muy pequeña  $n$  compara con todo el espacio  $r$  y  $r_1$  entonces entonces bien que puedes tener toda la mala suerte de que todas caigan donde tu no querías por lo tanto, podría pasar que  $X = 0$ , pero, pero que pasaría que tu  $n$  fuera lo suficientemente grande tal que si que si entrará todo tus fragmentos que no quieres entonces lo mínimo que puede entrar es  $n - r_2$ .

El cálculo para el límite mayor es parecido.

Solemos entonces escribir esta distribución como:

$$X \sim H(x; n, r_1, r_2)$$

donde:

- $x$ : Nuestra variable
- $n$ : Tamaño de la muestra
- $r$ : Tamaño de TODA la población
- $r_1$ : Tamaño de nuestra población de interes
- $r_2$ : Tamaño de la población que no es de interes, sale de  $r_2 = r - r_1$

### 4.4.2. Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = \frac{\binom{r_1}{x} \binom{r_2}{n-x}}{\binom{r}{n}}$$

**Idea de la Demostración:**

Antes que nada, mira lo bonito que sale, arriba tienes  $r_1, r_2$  y  $r_1 + r_2 = r$  y abajo tienes que  $n - x, x$  y  $n - x + x = n$

Ahora, abajo estamos colocando las posibles formas de escoger conjunto de  $n$  elementos de una espacio de  $r$  elementos, y arriba es la probabilidad conjunta de que primero tengamos  $x$  elementos de  $r_1$  y  $n - x$  elementos de  $r_2$

### 4.4.3. Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^x \binom{r_1}{i} \binom{r_2}{n-i}$$

**Idea de la Demostración:**

Es por definición men :v

#### 4.4.4. Esperanza

Esta esta muy interesante:

$$E(X) = n \left( \frac{r_1}{r} \right)$$

**Demostración:**

Primero que nada porque usando la definición o algo así nos van a salir cosas horribles, así que mejor empecemos por otro lado.

Sea  $X_i$  variables aleatorias de Bernoulli, tal que esten definidas por:

$$X_i = \begin{cases} 1 & \text{Si } X_i \text{ es de tipo } r_1 \\ 0 & \text{Si } X_i \text{ no es de tipo } r_1 \end{cases}$$

Ahora, como son variables de Bernoulli, podemos encontrar bien facil su esperanza como  $E(X_i) = p = \frac{r_1}{r}$

Ahora, como ya te esperabas, nota que nuestra variable aleatoria hipergeometrica es la suma de las otras  $X = \sum_{i=1}^n X_i$

Ahora como la esperanza es un bonito operador lineal tenemos que:

$$\begin{aligned} E(X) &= E \left( \sum_{i=1}^n X_i \right) \\ &= \sum_{i=1}^n E(X_i) \\ &= \sum_{i=1}^n \frac{r_1}{r} \\ &= n \left( \frac{r_1}{r} \right) \end{aligned}$$



### 4.4.5. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = E(e^{tX}) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^{\min(n, r_1)} e^{ti} \binom{r_1}{i} \binom{r_2}{n-i}$$

## 4.5. Poisson

### Variable Aleatoria

La variable aleatoria que cuenta el número de ocurrencias en un periodo de tiempo o espacio físico dado se le llama Poisson.

$X$  : Número de ocurrencias en un periodo de tiempo o espacio dado

Ahora, los valores posibles que puede tomar es  $0, 1, 2, \dots$

Solemos entonces escribir esta distribución como:

$$X \sim P(x; \lambda)$$

donde:

- $x$ : Nuestra variable
- $\lambda$ : Es el número promedio de ocurrencias en el periodo o espacio dado

### 4.5.1. Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}$$

### 4.5.2. Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = e^{-\lambda} \sum_{i=0}^x \frac{\lambda^i}{i!}$$

**Idea de la Demostración:**

Es por definición men :v

### 4.5.3. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = e^{\lambda(e^t-1)}$$

**Demostración:**

Usando la función probabilidad puntual tenemos que:

$$\begin{aligned}
\Psi_X(t) &= E(e^{tX}) \\
&= \sum_{x=0}^{\infty} e^{tx} P(X = x) \\
&= \sum_{x=0}^{\infty} e^{tx} e^{-\lambda} \frac{\lambda^x}{x!} \\
&= e^{-\lambda} \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x}{x!} \\
&= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(e^t \lambda)^x}{x!} \\
&= e^{-\lambda} e^{e^t \lambda} \\
&= e^{\lambda(e^t-1)}
\end{aligned}$$

### 4.5.4. Esperanza

Esta es muy interesante:

$$E(X) = \lambda$$

**Demostración:**

Esta sale o bien por definición o usando la generadora de momentos y dicen que:

$$\begin{aligned}\Psi(t=0)' &= e^{\lambda(e^t-1)}\lambda(e^t) \Big|_{t=0} \\ &= e^0\lambda(e^0) \\ &= \lambda\end{aligned}$$

### 4.5.5. Varianza

Esta es muy interesante:

$$v(X) = \lambda$$

**Demostración:**

Esta sale o bien por definición o usando la generadora de momentos y dicen que:

$$\begin{aligned}\Psi(t=0)'' &= e^{\lambda(e^t-1)}\lambda(e^t) + \lambda(e^t)^2 e^{\lambda(e^t-1)} \Big|_{t=0} \\ &= \lambda + \lambda^2\end{aligned}$$

Por lo tanto la varianza es  $v(X) = \lambda + \lambda^2 - \lambda^2 = \lambda$

### 4.5.6. Relación con la Binomial

Considera  $X \sim \text{Bin}(x; n, p)$ , entonces cuando más grande sea  $n$  más nuestra binomial se va a parecer a una Poisson con  $\lambda = np$

**Demostración:**

Considera  $X \sim \text{Bin}(x; n, p)$ , entonces esta más que claro que por ser una variable aleatoria que se distribuye con una binomial que  $P(X = x) = f_X = \binom{n}{x} p^x q^{n-x}$ .

Ahora como ya demostramos en las propiedades de la Poisson, vamos a suponer por un minuto que  $\lambda = np$ , es decir  $p = \frac{\lambda}{n}$  entonces tenemos que:

$$P(X = x) = f_X = \binom{n}{x} p^x q^{n-x} = \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$$

Ahora veamos que es lo que pasa cuando tenemos una  $x$  muy muy grande, es decir:

$$\begin{aligned} \lim_{n \rightarrow \infty} P(X = x) &= \lim_{n \rightarrow \infty} \binom{n}{x} p^x q^{n-x} \\ &= \lim_{n \rightarrow \infty} \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \frac{\lambda^x}{n^x} \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{\lambda^x}{x!} \frac{n!}{n^x (n-x)!} \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \frac{\lambda^x}{x!} \lim_{n \rightarrow \infty} \frac{n-x+1}{n} \dots \frac{n-1}{n} \frac{n}{n} \left(1 - \frac{\lambda}{n}\right)^n \frac{1}{(n-\lambda)^x} \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \lim_{n \rightarrow \infty} \frac{n-x+1}{n} \dots \frac{n-1}{n} \frac{n}{n} \frac{1}{(n-\lambda)^x} \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \lim_{n \rightarrow \infty} (1) \dots (1) \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \end{aligned}$$

Por lo tanto cuando más grande sea  $n$  más nuestra binomial se va a parecer a una Poisson con  $\lambda = np$

# Bibliografía

- [1] Leticia Cañedo Suárez *Probabilidad*. ESCOM, 2018