
COMPILANDO CONOCIMIENTO

Probabilidad y Estadística

MATEMÁTICAS ESTADÍSTICAS

Oscar Andrés Rosas Hernandez

Febrero 2018

Índice general

I	Probabilidad Clásica	9
1.	Introducción	10
1.1.	Notación	11
1.1.1.	Experimento ε	11
1.1.2.	Espacio Muestral S, Ω	11
1.1.3.	Evento A	11
1.2.	Probabilidad $P(A)$	12
1.2.1.	Propiedades	13
1.3.	Probabilidad Condicional	14
1.3.1.	Propiedades	15
1.4.	Eventos Independientes	16
1.4.1.	Propiedades	16
1.4.2.	Teorema de Bayes	17
2.	Combinatoria	18
2.1.	Ideas Clave	19
2.1.1.	Orden vs Sin Orden	19
2.1.2.	Remplazar vs No Remplazar	19
2.2.	Permutación	20
2.2.1.	Ejemplos	20
2.3.	Combinación	21
2.3.1.	Combinaciones y Subconjuntos	21
2.3.2.	Ejemplos	21

2.3.3. Propiedades Coeficientes Binomiales	22
II Variables Aleatorias Discretas	23
3. Variables Aleatorias Discretas	24
3.1. Variables Aleatorias	25
3.1.1. Variables Aleatorias Discretas	25
3.2. Función Probabilidad f_X	26
3.2.1. Definición	26
3.2.2. Propiedades	26
3.2.3. Ejemplos	27
3.3. Función P. Acumulada F_X	28
3.3.1. Definición	28
3.3.2. Propiedades	28
3.3.3. Función Fundamental	28
3.4. Esperanza o Media	29
3.4.1. Definición	29
3.4.2. Propiedades	29
3.5. Varianza	30
3.5.1. Definición	30
3.5.2. Desviación Estandar	30
3.5.3. Propiedades	31
3.6. Covarianza	33
3.6.1. Definición	33
3.6.2. Propiedades	33
3.7. Momentos Centrales	34
3.7.1. Propiedades	34
3.7.2. Función Generadora de Momentos	35
3.7.3. Propiedades	36
4. Distribuciones Famosas	37

4.1. Bernoulli	38
4.1.1. Definición	38
4.1.2. Función Probabilidad	39
4.1.3. Función P. Acumulada	39
4.1.4. Esperanza	40
4.1.5. Varianza	40
4.1.6. Función Generadora	41
4.2. Binomial	42
4.2.1. Definición	42
4.2.2. Función Probabilidad	43
4.2.3. Función P. Acumulada	43
4.2.4. Esperanza	43
4.2.5. Varianza	44
4.2.6. Función Generadora	44
4.2.7. Propiedades	45
4.3. Geométrica	46
4.3.1. Definición	46
4.3.2. Función Probabilidad	47
4.3.3. Función P. Acumulada	47
4.3.4. Esperanza	48
4.3.5. Varianza	49
4.3.6. Función Generadora	50
4.3.7. Propiedades	51
4.4. Hiper-Geométrica	52
4.4.1. Definición	52
4.4.2. Función Probabilidad	54
4.4.3. Función P. Acumulada	54
4.4.4. Esperanza	55
4.4.5. Varianza	55
4.4.6. Función Generadora	56

4.4.7. Relación con la Binomial	57
4.5. Poisson	58
4.5.1. Función Probabilidad	59
4.5.2. Función P. Acumulada	59
4.5.3. Función Generadora	60
4.5.4. Esperanza	61
4.5.5. Varianza	61
4.5.6. Relación con la Binomial	62
4.5.7. Propiedades	63
III Variables Aleatorias Continuas	64
5. Variables Aleatorias Continuas	65
5.1. Variables Aleatorias	66
5.1.1. Variables Aleatorias Continuas	66
5.2. Función Probabilidad f_X	67
5.2.1. Definición	67
5.2.2. Probabilidad Puntual	67
5.3. Función P. Acumulada F_X	68
5.3.1. Definición	68
5.3.2. Propiedades	68
5.4. Esperanza	69
5.4.1. Definición	69
5.5. Varianza	69
5.5.1. Definición	69
5.6. Función Generadora de Momentos	69
5.6.1. Definición	69
6. Distribuciones Continuas Famosas	70
6.1. Uniforme	71
6.1.1. Definición	71

6.1.2.	Función Probabilidad	72
6.1.3.	Función P. Acumulada	72
6.1.4.	Esperanza	73
6.1.5.	Varianza	74
6.1.6.	Función Generadora	75
6.2.	Exponencial	76
6.2.1.	Definición	76
6.2.2.	Función Probabilidad	77
6.2.3.	Función P. Acumulada	77
6.2.4.	Función Generadora	78
6.2.5.	Esperanza	78
6.2.6.	Varianza	79
6.2.7.	Propiedades	80
6.3.	Gamma	81
6.3.1.	Función Gamma	81
6.3.2.	Definición	82
6.3.3.	Función Probabilidad	83
6.3.4.	Función Acumulada	83
6.3.5.	Generadora de Momentos	84
6.3.6.	Esperanza	85
6.3.7.	Varianza	85
6.3.8.	Propiedades	86
6.4.	Normal	87
6.4.1.	Definición	87
6.4.2.	Estandarización	87
6.4.3.	Función Probabilidad	88
6.4.4.	Generadora de Momentos	89
6.4.5.	Media	90
6.4.6.	Varianza	90
6.4.7.	Propiedades	91

7. Probabilidad Hardcore	92
7.1. Teorema Central del Límite	93
7.1.1. Definición	93
7.2. Teorema Central de Chebyshev	93
7.2.1. Definición	93
 IV Probabilidades Conjuntas	 94
8. Variables A. Multidimensionales	95
8.1. Función de Probabilidad	96
8.1.1. Discreto	96
8.1.2. Continuo	96
8.2. Distribución Acumulada	97
8.2.1. Discreto	97
8.2.2. Continuo	97
8.3. Distribución Marginal	98
8.3.1. Discreto	98
8.3.2. Continuo	98
8.4. Distribución Condicional	99
8.4.1. Discreto	99
8.4.2. Continuo	99
8.5. Independencia de Variables	100
8.5.1. Propiedades	100
 V Estimaciones	 101
9. Estimadores Puntuales	102
9.1. Características	103
9.1.1. Insesgado	103
9.1.2. Varianza Mínima	103
9.1.3. Optimo	104

9.1.4. Optimo	104
9.2. Método de los Momentos	105
9.3. Método de Máxima Verosimilitud	105
VI CheatSheet - Formulario	106
10.CheatSheet - Formulario	107
10.1. Teoría de Conjuntos	108
10.2. Combinatoria	109
10.2.1. Propiedades Coeficientes Binomiales	110
10.3. Probabilidad Básica	111
10.3.1. Propiedades	111
10.4. Probabilidad Condicional	112
10.4.1. Propiedades	112
10.5. Eventos Independientes	113
10.5.1. Propiedades	113
10.5.2. Teorema de Bayes	113
10.6. Variables Aleatorias Discretas	114
10.6.1. Función Probabilidad f_X	114
10.6.2. Función P. Acumulada F_X	115
10.6.3. Esperanza o Media	116
10.6.4. Varianza	117
10.6.5. Covarianza	118
10.6.6. Momentos Centrales	119
10.7. Distribuciones Discretas	121
10.7.1. Bernoulli	121
10.7.2. Binomial	122
10.7.3. Geométrica	123
10.7.4. HiperGeométrica	124
10.7.5. Poisson	126
10.8. Distribuciones Continuas	127

10.8.1. Uniforme	127
10.8.2. Exponencial	128
10.8.3. Gamma	129
10.8.4. Normal	130
10.9. Probabilidad Hardcore	131
10.9.1. Definición	131

Parte I

Probabilidad Clásica

Capítulo 1

Introducción

1.1. Notación

1.1.1. Experimento ε

Decimos que un experimento en probabilidad es cualquier proceso del cual se desconoce con determinación el resultado final.

Generalmente lo denotamos con mayúsculas.

1.1.2. Espacio Muestral S, Ω

Un espacio muestral asociado a un experimento es el conjunto de posibles resultados al momento de realizar el experimento.

Ejemplo:

Por ejemplo si ε_1 : Lanzar una moneda. Entonces tenemos que $S_1 = \{ Cara, Cruz \}$

Si ε_2 : Lanzar un dado. Entonces tenemos que $S_2 = \{ 1, 2, 3, 4, 5, 6 \}$

1.1.3. Evento A

Un evento es simplemente algún subconjunto del espacio muestral.

Ejemplo:

Por ejemplo si ε_1 : Lanzar una moneda. Entonces tenemos que un evento puede ser $A_1 = \{ Cara \}$

Si ε_2 : Lanzar un dado. Entonces tenemos que un evento puede ser $A_2 = \{ 1, 2, 4 \}, A_{2.1} = \{ 5 \}$

1.2. Probabilidad $P(A)$

Definimos la probabilidad de un evento A como:

$$P(A) = \frac{|A|}{|S|} \quad \text{Recuerda que } A \text{ es un evento y } S \text{ es espacio muestral}$$

Creo que es muy obvio por la manera en que definimos a la probabilidad de un evento es un número real entre 0 y 1.

Por lo tanto:

- **NO hay probabilidades negativas**
- **NO hay probabilidades mayores a uno**

Entonces podemos reducir el problema de encontrar la probabilidad de un evento simplemente a dos partes:

- Encontrar la cardinalidad de dicho evento
- Encontrar la cardinalidad del espacio muestral de un experimento

1.2.1. Propiedades

- $P(S) = 1$
- Si A_1, A_2, \dots, A_n son eventos mutuamente excluyentes entonces:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

- $P(\emptyset) = 0$
- $P(A') = 1 - P(A)$
- Si $A \subseteq B$ entonces $P(A) \leq P(B)$
- La probabilidad de la unión de n eventos se puede escribir de manera general como:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{i < j} P(A_i A_j) + \sum_{i < j < k} P(A_i A_j A_k) + \dots + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right)$$

- Por consecuencia del caso general tenemos que:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- Por consecuencia del caso general tenemos que:

$$\begin{aligned} P(A \cup B \cup C) = & P(A) + P(B) + P(C) \\ & - (P(A \cap B) + P(A \cap C) + P(B \cap C)) \\ & + P(A \cap B \cap C) \end{aligned}$$

- $P(A - B) = P(A) - P(A \cap B)$

1.3. Probabilidad Condicional

La probabilidad de que ocurra el Evento A conociendo que ya paso el Evento B se denota y define como:

$$P(A \mid B) := \frac{P(A \cap B)}{P(B)} = \frac{|A \cap B|}{|B|}$$

Nota que para que todo esto tenga sentido $P(B) \neq 0$

Podemos notar entonces que el evento B tiene muchas interpretaciones como:

- La condición que ya esta dada
- Evento que se sabe que ya ocurrió o que es seguro que ocurra
- Espacio Muestral Reducido

1.3.1. Propiedades

■ Conservamos Propiedades

La propiedad condicional cumple las propiedades que ya vimos de una propiedad de un evento cualquiera, pero ahora el espacio muestral que antes era S se ha reducido.

- $P(A \mid B) + P(A' \mid B) = 1$
- $P(A \cup B \mid C) = P(A \mid C) + P(B \mid C) - P(A \cap B \mid C)$

■ Definición Alternativa

Podemos redefinir a la probabilidad condicional como: $P(A \mid B) = \frac{|A \cap B|}{|B|}$

Demostración:

Esta es sencilla, muy sencilla:

$$\begin{aligned}
 P(A \mid B) &= \frac{P(A \cap B)}{P(B)} && \text{Por definición de Condicional} \\
 &= \frac{\frac{|A \cap B|}{|S|}}{\frac{|B|}{|S|}} && \text{Por definición de Probabilidad} \\
 &= \frac{|A \cap B|}{|B|} && \text{Magia}
 \end{aligned}$$

■ Regla de Multiplicación

Podemos escribir a $P(A \cap B)$ en terminos de probabilidad condicional.

$$P(A \cap B) = P(A|B) P(B) = P(B|A) P(A)$$

Demostración:

Mira: Si $P(A|B) = \frac{P(A \cap B)}{P(B)}$ entonces $P(A|B)P(B) = P(A \cap B)$

$P(B|A) = \frac{P(B \cap A)}{P(A)}$ entonces $P(B|A)P(A) = P(A \cap B)$

1.4. Eventos Independientes

Dados 2 eventos que A, B son Independientes si y solo si $P(A) = P(A|B)$ y se escribe: $A \perp B$.

Es decir la ocurrencia de B no influye en nada a la ocurrencia de A , osea que pase o no pase B , a A le da igual.

1.4.1. Propiedades

- Si $A \perp B$ entonces $P(A \cap B) = P(A)P(B)$

Demostración:

Si $A \perp B$ entonces $B \perp A$ entonces $P(B) = P(B|A)$, por lo tanto $P(B) = \frac{P(B \cap A)}{P(A)}$

Y solo despejas

- Si $A \perp B$ entonces $A' \perp B'$

Demostración:

Esta es clave:

$$\begin{aligned} P(A' \cap B') &= P((A \cup B)') \\ &= 1 - [P(A) + P(B) + P(A \cap B)] \\ &= 1 - [P(A) + P(B) + P(A \cap B)] \\ &= (1 - P(A))(1 - P(B)) \\ &= P(A')P(B') \end{aligned}$$

- Si $A \perp B$ entonces $P(A \cap B) \neq 0$
- Si $P(A \cap B) = 0$ entonces A, B no son eventos independientes
- $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$

1.4.2. Teorema de Bayes

Considera un conjunto de eventos $\{A_1, \dots, A_n\}$ mutuamente excluyentes y tales que $\bigcup_{i=1}^n A_i = S$, es decir son particiones de S .

Entonces podemos escribir la probabilidad de un evento B donde $B \subset S$ como:

$$P(B) = \sum_{i=1}^n P(B|A_i) P(A_i)$$

Gracias a esto podemos decir que:

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B|A_i) P(A_i)}{\sum_{i=1}^n P(A_i) P(B|A_i)} \end{aligned}$$

Capítulo 2

Combinatoria

2.1. Ideas Clave

2.1.1. Orden vs Sin Orden

En las muestras que estan ordenadas entonces el orden de los elementos importa por ejemplo en los dígitos de un teléfono o en las letras de una palabra.

En las muestras que no estan ordenadas el orden es irrelevante, por ejemplo en los elementos de un conjunto.

2.1.2. Remplazar vs No Remplazar

Las muestras con remplazo entonces estan permitidas, por ejemplo los números de la licencia.

Cuando la repetición no esta permitida, por ejemplo en un conjunto de números de lotería

2.2. Permutación

Una permutación es un arreglo de objetos donde el orden es importante.

Entonces definimos a ${}_nP_r$ a la cantidad de muestras ordenadas de tamaño r sin remplazo de un conjunto de n objetos.

Entonces decimos que:

$${}_nP_r = \frac{n!}{(n-r)!} = (n)(n-1)(n-2)\dots(n-r+1)$$

2.2.1. Ejemplos

Ejemplo 1:

Considera $S = \{a, b, c, d\}$, entonces podemos decir que:

- Hay 4 permutaciones distintas tomando solo una letra a la vez
- Hay 12 permutaciones distintas tomando solo dos letra a la vez
- Hay 24 permutaciones distintas tomando solo tres letra a la vez

Estas se pueden sacar facilmente con esta idea que creo que a todos nos enseñan, por ejemplo veamos como hacer el último punto:

$$\begin{array}{ccc} \underline{4} & \underline{3} & \underline{2} \\ \text{\# De Posibles Elementos} & \text{\# De Posibles Elementos} & \text{\# De Posibles Elementos} \end{array} = (4)(3)(2) = 24$$

2.3. Combinación

Una permutación es un arreglo de objetos donde el orden NO es importante.

Entonces definimos a ${}_nC_r$ a la cantidad de muestras sin ordenadas de tamaño r sin remplazo de un conjunto de n objetos.

Entonces decimos que:

$$\binom{n}{r} = {}_nC_r = \frac{{}_nP_r}{r!} = \frac{n!}{r!(n-r)!} = \frac{(n)(n-1)(n-2)\dots(n-r+1)}{r!}$$

Esto tiene mucho sentido si lo ves desde otro angulo, pues en cuanto a las permutaciones tendremos $(n)(n-1)(n-2)\dots(n-r+1)$, pero resulta que muchas de esas permutaciones son basicamente la misma, solo cambiando el orden, así que si el orden ya no importa, es tan sencillo como dividir entre la cantidad de veces que podemos ordenar esas permutaciones de tamaño r

2.3.1. Combinaciones y Subconjuntos

Resulta ser que hay dos grande problemas clásicos de teoría de conjuntos que podemos resolver con combinaciones:

- El número de subconjuntos de cardinalidad r de un conjunto de n elementos

$$\binom{n}{r}$$

- Número de subconjuntos de un conjunto de n elementos:

$$\sum_{i=0}^n \binom{n}{i} = 2^n$$

2.3.2. Ejemplos

Ejemplo 1:

Cuantos equipos se puede formar que incluyan 2 físicos y 1 matemático si se sabe que hay 4 físicos y 3 matemáticos.

Ya que no nos importa el orden esto esta mas sencillo de lo que parece:

$$\binom{4}{2} \binom{3}{1} = \frac{4!}{2!(4-2)!} \frac{3!}{1!(3-1)!} = 18$$

2.3.3. Propiedades Coeficientes Binomiales

- Propiedades Simétricas

$$\binom{n}{k} = \binom{n}{n-k}$$

- Casos Especiales

$$\binom{n}{0} = \binom{n}{n} = 1 \qquad \binom{n}{1} = \binom{n}{n-1} = n$$

- Teorema del Binomio

$$(x + y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$$

- Teorema del Binomio (Caso Especial)

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = 1$$

Parte II

Variables Aleatorias Discretas

Capítulo 3

Variables Aleatorias Discretas

3.1. Variables Aleatorias

Una variable aleatoria es una función que asigna a cada elemento $E_i \in S$ en el espacio muestral a un número real $X(E_i) \in \mathbb{R}$, es decir, en español, lo que hace es que es una función que nos da información de una característica de cada elemento del espacio muestral.

Esta se denota con mayúsculas y no es un número, es una función. Para poner a un valor posible de una variable aleatoria lo denotamos con minúsculas.

3.1.1. Variables Aleatorias Discretas

Las variables aleatorias cuyo conjunto de valores posibles es finito o infinito contable entonces decimos que es una variable aleatoria discreta.

Ejemplo:

Por ejemplo considera que vas a lanzar 3 monedas, entonces tenemos que:

$$S = \{ ccc, ccx, cxc, xcc, xxc, xcx, cxx, xxx \}$$

Entonces podemos tener una variable aleatoria como:

Sea X = Número de caras en 3 lanzamientos.

Entonces podemos decir que:

$$\begin{aligned} X(ccc) &= 3 \\ X(ccx) &= 2 \\ X(cxc) &= 2 \\ X(xcc) &= 2 \\ X(xxc) &= 1 \\ X(xcx) &= 1 \\ X(cxx) &= 1 \\ X(xxx) &= 0 \end{aligned}$$

Por lo tanto los vales posibles son 0, 1, 2, 3.

3.2. Función Probabilidad f_X

3.2.1. Definición

También se le conoce como función de probabilidad puntual. Es una función que toma todos los posibles valores una variable aleatoria y nos regresa un número real entre el 0 y el 1 dado por la probabilidad de el valor de la variable aleatoria sea x . Es decir:

$$f_X(x) = P(X = x)$$

3.2.2. Propiedades

Es una función de probabilidad, es decir tiene que cumplir que la suma de todos los posibles valores de la variable aleatoria den uno.

Más formalmente tenemos que la función probabilidad es aquella función que cumple que:

- $\forall a \in \mathbb{R} \quad 0 \leq f_X(a) \leq 1$
- $\{ x \mid f_X(x) \neq 0 \}$ es un conjunto finito o numerable
- $\sum_x f_X(x) = 1$

3.2.3. Ejemplos

Ejemplo:

Por ejemplo podemos definir la probabilidad del ejemplo pasado podemos definir la función

$$f_X(x) = \binom{3}{x} \left(\frac{1}{2}\right)^x \left(\frac{1}{2}\right)^{3-x} \text{ para } x \in \{0, 1, 2, 3\}$$

Entonces tenemos que:

- La probabilidad de que $X = 0$ (caigan 0 caras) es $\frac{1}{8}$
- La probabilidad de que $X = 1$ (caigan 1 caras) es $\frac{3}{8}$
- La probabilidad de que $X = 2$ (caigan 2 caras) es $\frac{3}{8}$
- La probabilidad de que $X = 3$ (caigan 3 caras) es $\frac{1}{8}$

3.3. Función P. Acumulada F_X

3.3.1. Definición

Describimos a la función de probabilidad acumulada como:

$$F_X(x) = \sum_{i \leq x} f_X(i)$$

3.3.2. Propiedades

- Una característica muy común es que:
 - $\lim_{x \rightarrow -\infty} F_X(x) = 0$
 - $\lim_{x \rightarrow \infty} F_X(x) = 1$
- Si $x_1 \leq x_2$ entonces $F_X(x_1) \leq F_X(x_2)$

3.3.3. Función Fundamental

Podemos ver a la acumulada como una función fundamental, tal que podemos escribir a todas las demás:

- $P(X = x) = F_X(x) - F_X(x - 1)$
- $P(X < x) = F_X(x - 1)$
- $P(X \leq x) = F_X(x)$
- $P(X > x) = 1 - F_X(x)$
- $P(X \geq x) = 1 - F_X(x - 1)$
- $P(a \leq X \leq b) = F_X(b) - F_X(a - 1)$
- $P(a < X \leq b) = F_X(b) - F_X(a)$
- $P(a \leq X < b) = F_X(b - 1) - F_X(a)$
- $P(a < X < b) = F_X(b - 1) - F_X(a - 1)$

3.4. Esperanza o Media

3.4.1. Definición

Decimos que el valor esperado, esperanza ó media de la variable X se define como:

$$\mu_X = E(X) = \sum_x x f_X(x) = \sum_x x P(X = x)$$

Representa un promedio ponderado de los valores posibles de la variable basado en sus probabilidades.

Es decir, si se repitiera el experimento muchísimas veces el promedio de los resultados se iría aproximando a la media.

3.4.2. Propiedades

- Si X puede tomar un número infinito de valores entonces la esperanza de X existe si y solo si $\sum_x |x| f_X(x) < \infty$
- Podemos dar una definición al evaluar la esperanza sobre una función:

$$E(g(x)) = \sum_x g(x) f_X(x)$$

- Es un Operador Lineal, es decir:

$$E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$$

- Si X, Y son independientes entonces:

$$E(XY) = E(X)E(Y)$$

- Si a es una constante, entonces:

$$E(a) = a$$

3.5. Varianza

3.5.1. Definición

Decimos que la varianza de la variable X con $f_X(x)$ se define como:

$$v(X) = E((X - \mu)^2)$$

Podemos decir por su misma definición que la varianza siempre es positiva.

Es decir, este valor nos indica que tan lejos estan en promedio los valores de su misma media, es decir, que tan dispersa o concentrada esta la distribución de los datos.

3.5.2. Desviación Estandar

Decimos que la desviación estandar de la variable X con $f_X(x)$ se define como:

$$\sigma(X) = \sqrt{v(X)}$$

Se usa generalmente por las unidades que tiene la varianza, nada mas

3.5.3. Propiedades

■ $v(X) = E(X^2) - (E(X))^2$

Demostración:

Esto es demasiado sencillo:

$$\begin{aligned} v(X) &= E((X - \mu)^2) \\ &= E(X^2 - 2X\mu + \mu^2) \\ &= E(X^2) - E(2X\mu) + E(\mu^2) \\ &= E(X^2) - 2\mu E(X) + E(\mu^2) \\ &= E(X^2) - 2\mu^2 + \mu^2 \\ &= E(X^2) - \mu^2 \end{aligned}$$

■ $V(a) = 0$

Demostración:

Sea $a = g(X)$, entonces su $\mu = a$, por lo tanto

$$\begin{aligned} V(a) &= E(a - a)^2 \\ &= E(0)^2 \\ &= 0 \end{aligned}$$

■ $v(aX) = a^2v(X)$

Demostración:

$$\begin{aligned} V(aX) &= E(aX^2) - E^2(aX) \\ &= a^2E(X^2) - a^2E^2(X) \\ &= a^2[E(X^2) - E^2(X)] \\ &= a^2[v(X)] \end{aligned}$$

■ $v(X + Y) = v(X) + v(Y) + 2Cov(X, Y)$

Demostración:

Esta es larga:

$$\begin{aligned} v(X + Y) &= E(X + Y)^2 - (E(X + Y))^2 \\ &= E(X) + E(Y) + 2E(XY) - (E(X) + E(Y))^2 \\ &= E(X) + E(Y) - (E(X) + E(Y))^2 + 2E(XY) \\ &= E(X) + E(Y) - E^2(X) - E^2(Y) + 2E(XY) - 2E(X)E(Y) \\ &= E(X) - E^2(X) + E(Y) - E^2(Y) + 2E(XY) - 2E(X)E(Y) \\ &= v(X) + v(Y) + 2E(XY) - 2E(X)E(Y) \\ &= v(X) + v(Y) + 2Cov(X, Y) \end{aligned}$$

- $v(aX + bY) = a^2v(X) + b^2v(Y) + 2ab \operatorname{Cov}(X, Y)$
- $v(X - Y) = v(X) - v(Y) - 2\operatorname{Cov}(X, Y)$

Demostración:

Es lo mismo, que la de arriba :v

- Si X y Y son independientes, entonces $v(X + Y) = v(X) + v(Y)$

Demostración:

Es lo mismo que la de arriba, solo recuerda que si X, Y son independientes entonces tenemos que $\operatorname{Cov}(X, Y) = 0$

- En general si X_1, X_2, \dots, X_n son variables aleatorias, entonces tenemos que:

$$v\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n v(X_i) + 2 \sum_{i < j}^n \operatorname{Cov}(X_i, X_j)$$

Demostración:

Es inducción :v

3.6. Covarianza

3.6.1. Definición

Sea X, Y dos variables independientes, entonces definimos a la covarianza como:

$$\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y))$$

Es una manera de medir la dispersión conjunta de ambas variables.

3.6.2. Propiedades

- $\text{Cov}(X, Y) = E(XY) - \mu_X\mu_Y$

Demostración:

Podemos demostrar esto, bien facil:

$$\begin{aligned} \text{Cov}(X, Y) &= E((X - \mu_X)(Y - \mu_Y)) \\ &= E(XY - X\mu_Y - \mu_X Y + \mu_X\mu_Y) \\ &= E(XY) - E(X\mu_Y) - E(\mu_X Y) + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y E(X) - \mu_X E(Y) + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y\mu_X - \mu_X\mu_Y + E(\mu_X\mu_Y) \\ &= E(XY) - \mu_Y\mu_X - \mu_X\mu_Y + \mu_X\mu_Y \\ &= E(XY) - \mu_Y\mu_X \end{aligned}$$

- La covarianza de 2 variables independientes es cero

Demostración:

Mira esto:

$$\begin{aligned} \text{Cov}(X, Y) &= E(XY) - \mu_Y\mu_X \\ &= E(X)E(Y) - \mu_Y\mu_X \\ &= 0 \end{aligned}$$

Si es que son independientes

Recuerda que $E(X) = \mu_X$

3.7. Momentos Centrales

Si X es una variable aleatoria tal que $E(X) = \mu_x$ entonces tenemos que:

- El k -ésimo momento central esta definida como:

$$\mu_k^c = E[(X - \mu)^k] = \sum_x (x - \mu)^k P(X = x) \quad (3.1)$$

- El k -ésimo momento alrededor del origen esta definida como:

$$\mu_k^0 = E(X^k) = \sum_x x^k P(X = x) \quad (3.2)$$

3.7.1. Propiedades

- Ya hemos trabajado con momentos, veamos algunos:

- **La Esperanza**

Esta se puede ver como el primer momento alrededor del origen

$$\mu_X = \mu_1^0$$

- **La Varianza**

Esta se puede ver como el primer momento alrededor central

$$v(X) = E[(X - \mu)^2] = \mu_2^c$$

O bien podemos verlo como $v(X) = E(X^2) - \mu^2$ donde $E(X^2)$ es un segundo momento alrededor del origen

3.7.2. Función Generadora de Momentos

La podemos definir como:

$$\Psi_X(t) = E(e^{tX}) = \sum_x e^{tx} P(X = x)$$

Solemos decir que la k-ésima derivada de la función generadora de momentos evaluada en $t = 0$ da como resultado el k-ésimo momento central al origen

Es decir, siguen el siguiente patrón:

- $\Psi'_X(t = 0) = E(X)$
- $\Psi''_X(t = 0) = E(X^2)$
- $\Psi'''_X(t = 0) = E(X^3)$
- $\Psi_X^{(n)}(t = 0) = E(X^n)$

3.7.3. Propiedades

- Nota que $\Psi_x(a) = E(e^{aX})$
- Si $Y = aX + b$ entonces tenemos que:
 $\Psi_Y(t) = e^{bt}\Psi_X(at)$

Demostración:

Esta es fácil, sea $Y = aX + b$:

$$\begin{aligned}\Psi_Y(t) &= E(e^{tY}) \\ &= E(e^{t(aX+b)}) \\ &= E(e^{atX+tb}) \\ &= E(e^{atX}e^{tb}) \\ &= e^{tb}E(e^{atX}) \\ &= e^{tb}\Psi_X(at)\end{aligned}$$

- $\Psi_X(t=0) = \mu_k$
- $\Psi_X(t=0) = E(X)$
- Nota que si tuvieramos un montón de variables aleatorias $X_1, X_2, X_3, \dots, X_n$ Y decimos que $Y = \sum_{i=1}^n X_i$

Entonces tenemos que:

$$\Psi_Y(t) = \prod_{i=1}^n \Psi_{X_i}(t)$$

Demostración:

Esta también es importante:

$$\begin{aligned}\Psi_Y(t) &= E(e^{tY}) \\ &= E\left(e^{t\sum_{i=1}^n X_i}\right) \\ &= E\left(\prod_{i=1}^n e^{tX_i}\right) \\ &= \prod_{i=1}^n E(e^{tX_i}) \\ &= \prod_{i=1}^n \Psi_{X_i}(t)\end{aligned}$$

Capítulo 4

Distribuciones Famosas

4.1. Bernoulli

4.1.1. Definición

Suponte un experimento en el que solo tienes dos salidas, 0, 1, 0 para el fracaso y 1 para el éxito, suponte que la probabilidad de que salga 1 es p y la que salga 0 es $q = 1 - p$.

Variable Aleatoria

Ahora, nuestra variable aleatoria será:

X : Resultado del experimento

Ahora, los valores posibles que puede tomar son muy muy sencillos, básicamente porque solo hay 2 opciones, o salió bien, o salió mal, es decir X puede tomar los valores 0, 1.

Solemos entonces escribir esta distribución como:

$$X \sim \text{Ber}(x; p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito

4.1.2. Función Probabilidad

Esta es clásica:

$$f_X(x) = (p^x)((1-p)^{1-x}) = p^x q^{1-x}$$

Demostración:

Esta es fácil, podemos hacerla por partes, como parece más natural y ver que:

$$F_X(x) = \begin{cases} q & x = 0 \\ p & x = 1 \end{cases}$$

Podemos extender esta idea de muchas maneras a una expresión, la que damos es solo una de ellas.

4.1.3. Función P. Acumulada

Por definición tenemos que:

$$F_X(x) = \begin{cases} 0 & x < 0 \\ q & 0 \leq x < 1 \\ p & 1 \leq x \end{cases}$$

Y esta conviene mejor dejarla así.

4.1.4. Esperanza

Esta es la distribución con la esperanza más fácil que veras:

$$E(X) = p$$

Demostración:

Nota que por definición tenemos que:

$$\begin{aligned}\mu_X &= \sum_x xP(X = x) \\ &= 0(q) + 1(p) \\ &= p\end{aligned}$$

4.1.5. Varianza

Esta es igualmente sencilla:

$$v(X) = p(1 - p) = p - p^2 = pq$$

Demostración:

Por definición tenemos que:

$$\begin{aligned}v(X) &= E(x^2) - \mu^2 \\ &= E(x^2) - p^2 \\ &= \sum_x x^2 P(X = x) - p^2 \\ &= 0(q) + 1(p) - p^2 \\ &= p - p^2 \\ &= p(1 - p) \\ &= pq\end{aligned}$$

4.1.6. Función Generadora

Esta igual es muy bonita:

$$\Psi(t) = (q) + e^t(p)$$

Demostración:

Por definición tenemos que:

$$\begin{aligned}\Psi(t) &= E(e^t X) \\ &= \sum_x e^t x P(X = x) \\ &= e^{0t}(q) + e^{1t}(p) \\ &= (q) + e^t(p)\end{aligned}$$

4.2. Binomial

4.2.1. Definición

Un experimento binomial consiste en n ensayos Bernoulli independientes, con una probabilidad de éxito individual constante e igual en todos los experimentos

La variable aleatoria discreta nos medirá el número de éxitos de los experimentos individuales, donde sus posibles valores fueron $X = \{0, 1, \dots, n\}$.

Observa que la variable aleatoria se puede ver como la suma de Bernoullis independientes, es decir $X = X_1 + X_2 + X_3 + \dots + X_n$

Variable Aleatoria

Ahora, nuestra variable aleatoria será:

X : Número de Éxitos en los experimentos

Ahora, los valores posibles que puede tomar son muy muy sencillos, suponte que haremos n experimentos, entonces X tiene que tomar valores entre $0 \dots n$

Solemos entonces escribir esta distribución como:

$$X \sim \text{Bin}(n, p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito de cada experimento Bernoulli

Definición Alterna

Sea X_i variables aleatorias de Bernoulli, tal que estén definidas por:

$$X_i = \begin{cases} 1 & \text{Si el } i \text{ésimo experimento fue exitoso} \\ 0 & \text{Si el } i \text{ésimo experimento fue un fallo} \end{cases} \quad \forall i \in [1, 2, \dots, n]$$

Nota que cada X_i es independiente

Entonces podemos ver a una Binomial como suma de Bernoulli INDEPENDIENTES es decir:

$$X = X_1 + X_2 + \dots + X_n$$

4.2.2. Función Probabilidad

Esta esta fácil:

$$f_X(x) = \binom{n}{x} p^x q^{n-x}$$

Demostración:

¿Porque? Porque estamos hablando de eventos independientes por lo tanto su probabilidad conjunta es el producto de las individuales, y literalmente estamos usando la definición de combinación.

4.2.3. Función P. Acumulada

Esta esta fácil:

$$F_X(x) = \sum_{i=0}^x \binom{n}{i} p^i q^{n-i}$$

Demostración:

Literalmente es la definición.

4.2.4. Esperanza

Esta también es sencilla:

$$E(X) = np$$

Demostración:

Podemos usar que la variable aleatoria se puede ver como la suma de Bernoullis independientes.

Es decir $X = \sum_x X_i$

$$\begin{aligned} \mu_X &= E(X) \\ &= E\left(\sum_x X_i\right) \\ &= \sum_x E(X_i) \\ &= np \end{aligned}$$

4.2.5. Varianza

Esta es bonita también:

$$v(X) = npq$$

Demostración:

Esta la haremos usando propiedades de la varianza, recuerda que son la suma de eventos independientes:

$$\begin{aligned} v(X) &= v\left(\sum_{i=0}^n X_i\right) \\ &= \sum_{i=1}^n v(X_i) \\ &= \sum_{i=1}^n pq \\ &= npq \end{aligned}$$

4.2.6. Función Generadora

Por definición tenemos que:

$$\Psi(t) = (q + e^t p)^n$$

Demostración:

Espera, espera, me explico mejor, lo que pasa es la binomial se puede ver como una suma de variables independientes entonces solo basta con recordar que ya demostramos que la función generadora de momentos de una suma de variables independientes es el producto de la función generadora de momentos de cada una.

Es decir:

$$\begin{aligned} \Psi_X(t) &= \Psi_{\sum_{i=1}^n X_i}(t) \\ &= \prod_{i=1}^n \Psi_{X_i}(t) \\ &= \prod_{i=1}^n (q + e^t p) \\ &= (q + e^t p)^n \end{aligned}$$

4.2.7. Propiedades

- Sean X_1, X_2, \dots, X_k k variables aleatorias discretas independientes y $X_i \sim \text{Bin}(x_i; n_i, p)$ con $i = 1, 2, \dots, k$.

Entonces la variable aleatoria $X = X_1 + X_2 + \dots + X_k$ tiene una distribución binomial tal que $X \sim \text{Bin}\left(x; \sum_{i=1}^k n_i, p\right)$

Demostración:

Veamos que:

$$\begin{aligned}
 \Psi_X(t) &= \Psi_{X_1+X_2+\dots+X_k}(t) \\
 &= \prod_{i=1}^k \Psi_{X_i} \\
 &= (q + pe^t)^{n_1} (q + pe^t)^{n_2} \dots (q + pe^t)^{n_k} \\
 &= (q + pe^t)^{\sum_{i=1}^k n_i}
 \end{aligned}$$

Es decir $\Psi_X(t) = (q + pe^t)^n$ con $n = \sum_{i=1}^k n_i$, es decir vimos que $X \sim \text{Bin}\left(x; \sum_{i=1}^k n_i, p\right)$

4.3. Geométrica

4.3.1. Definición

Supón que se repiten de manera independiente ensayos Bernoulli con una probabilidad de éxito constante de p hasta obtener el primer éxito.

La variable discreta es el número de experimentos hasta un primer éxito, donde sus posibles valores son $X = \{1, 2, 3, \dots\}$.

Variable Aleatoria

Ahora, nuestra variable aleatoria será:

X : Número de experimentos hasta un éxito

Ahora, los valores posibles que puede tomar son muy muy sencillos, porque puede que pase en el primer experimento o en el segundo, es decir la variable aleatoria puede tomar cualquier valor en los enteros positivos.

Solemos entonces escribir esta distribución como:

$$X \sim G(x; p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito de cada experimento Bernoulli

4.3.2. Función Probabilidad

Esta esta fácil:

$$f_X(x) = q^{x-1} p$$

Es decir, es la propabilidad de que todos los anteriores sean fracasos y el actual sea el éxito.

4.3.3. Función P. Acumulada

Esta también es sencilla:

$$F_X(x) = 1 - q^x$$

Demostración:

Esta esta fácil, solo espero que recuerdes la suma de la serie geométrica:

$$\begin{aligned}
F_X(x) &= \sum_{i=1}^x pq^{i-1} \\
&= (p) \sum_{i=0}^{x-1} q^i \\
&= (p) \frac{1 - q^x}{1 - q} \\
&= (p) \frac{1 - q^x}{p} \\
&= 1 - q^x
\end{aligned}$$

4.3.4. Esperanza

Esta es muy famosa, y lo repito, que no se te olvide la geométrica

$$E(X) = \frac{1}{p}$$

Demostración:

$$\begin{aligned} E(X) &= \sum_{x=1}^{\infty} xP(X=x) \\ &= \sum_{x=1}^{\infty} xq^{x-1}p \\ &= p \sum_{x=1}^{\infty} xq^{x-1} \\ &= p \frac{d}{dx} \sum_{x=1}^{\infty} q^x \\ &= p \frac{d}{dx} \frac{1}{1-q} \\ &= p \frac{1}{(1-q)^2} \\ &= p \frac{1}{p^2} \\ &= \frac{1}{p} \end{aligned}$$

4.3.5. Varianza

Esta también es sencilla:

$$v(X) = \frac{1-p}{p^2}$$

Demostración:

$$\begin{aligned} v(X) &= E(X^2) - \mu^2 \\ &= E(X^2) - \frac{1}{p^2} \\ &= \sum_{x=1}^{\infty} x^2 P(X=x) - \frac{1}{p^2} \\ &= \sum_{x=1}^{\infty} x^2 pq^{x-1} - \frac{1}{p^2} \\ &= p \sum_{x=1}^{\infty} x^2 q^{x-1} - \frac{1}{p^2} \\ &= p \frac{1+q}{(1-q)^3} - \frac{1}{p^2} \\ &= \frac{1+q}{p^2} - \frac{1}{p^2} \\ &= \frac{q}{p^2} \\ &= \frac{1-p}{p^2} \end{aligned}$$

4.3.6. Función Generadora

Esta también saldra por definición no somos cobardes:

$$\Psi(t) = \frac{pe^t}{1 - qe^t}$$

Demostración:

Por definición tenemos que:

$$\begin{aligned}\Psi(t) &= E(e^{tX}) \\ &= \sum_{x=1}^{\infty} e^{tx} q^{x-1} p \\ &= p \sum_{x=1}^{\infty} e^{tx} q^{x-1} \\ &= p \sum_{x=1}^{\infty} e^{tx} q^{x-1} \\ &= pe^t \sum_{x=1}^{\infty} (qe^t)^{x-1} \\ &= pe^t \frac{1}{1 - qe^t} \\ &= \frac{pe^t}{1 - qe^t}\end{aligned}$$

4.3.7. Propiedades

- Sea $X \sim G(x; p)$ entonces tenemos que $P(X > a) = q^a$ con a un natural positivo

Demostración:

$$\begin{aligned}
 P(Y > a) &= 1 - F_X(a) && \text{Definición de Acumulada} \\
 &= 1 - (1 - q^a) && \text{Talacha} \\
 &= q^a && \text{Bingo}
 \end{aligned}$$

- Podemos decir que esta distribución no tiene memoria es decir que ya voy a experimentos y no ha pasado nada entonces, debería ya ser mas probable que para $a + b$ ya me tocará, me explico mejor ... ¿No? ¡Pues no!

Espera, me explico mejor:

Sea $X \sim G(x; p)$ entonces $P(X > a + b \mid X > a) = P(X > b)$ con a, b un naturales positivos

Demostración:

$$\begin{aligned}
 P(X > a + b \mid X > a) &= \frac{P(X > a + b \text{ y } X > a)}{P(X > a)} && \text{Definición de Condicional} \\
 &= \frac{P(X > a + b)}{P(X > a)} && \text{Sentido común} \\
 &= \frac{p^{a+b}}{p^a} && \text{Teorema pasado} \\
 &= p^{(a+b)-a} && \text{Exponentes} \\
 &= p^b && \text{Usando teorema pasado} \\
 &= P(X > b)
 \end{aligned}$$

4.4. Hiper-Geométrica

4.4.1. Definición

Supongamos que tenemos una población de tamaño r , ahora esta particionado de 2 maneras, con elementos del tipo r_1 o r_2 , consideraremos exitosos los elementos de tipo r_1

Ahora vamos a tomar una muestra aleatoria de tamaño n sin reemplazo ni sustitución.

Ahora, solo por notación si es que n , es decir la muestra es menor que nuestra población r la llamamos muestra, pero si $n = r$ entonces decimos que es un censo.

Variable Aleatoria

Ahora, nuestra variable aleatoria sera:

X : Número de elementos del tipo r_1 en una muestra aleatoria de tamaño n

Ahora, los valores posibles que puede tomar son $\max(0, n - r_2) \leq x \leq \min(r_1, n)$

Ahora, ¿Porque esos números tan feos?

Por un lado tenemos que que lo peor que nos puede pasar son dos cosas:

- O bien si el tamaño de tu muestra n es muy pequeña, entonces puedes tener toda la mala suerte del mundo y que pase que todas caigan donde tu no querías por lo tanto, podría pasar que no seleccionará ningún elemento de r_1 entonces $X = 0$.
- Pero, pero que pasaría que tu n fuera lo suficientemente grande tal que incluso si seleccionará todos los que no quería r_2 , aún quedarán elementos por seleccionar, entonces los mínimos elementos r_1 que podría seleccionar es $n - r_2$, entonces $X = n - r_2$

El cálculo para el límite mayor es parecido

- Si tienes que $n \leq r_1$, entonces lo mejor que te puede pasar es que todos caigan donde tu quieras
- Si es que $n > r_1$ entonces puedes seleccionar todos los elementos de r_1

Solemos entonces escribir esta distribución como:

$$X \sim H(x; r_1, r_2, n)$$

donde:

- x : Nuestra variable
- r_1 : Tamaño de nuestra población de interes
- r_2 : Tamaño de la población que no es de interes, sale de $r_2 = r - r_1$
- n : Tamaño de la muestra

Definición Alterna

Sea X_i variables aleatorias de Bernoulli, tal que esten definidas por:

$$X_i = \begin{cases} 1 & \text{Al sacar el elemento i-esímo fue de tipo } r_1 \\ 0 & \text{Al sacar el elemento i-esímo NO fue de tipo } r_1 \end{cases} \quad \forall i \in [1, 2, \dots, n]$$

Entonces podemos ver a una hipergeométrica como:

$$X = X_1 + X_2 + \dots + X_n$$

Lo importante aquí es que como cada una de ellas no son independientes

4.4.2. Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = \frac{\binom{r_1}{x} \binom{r_2}{n-x}}{\binom{r}{n}}$$

Idea de la Demostración:

Antes que nada, mira lo bonito que sale, arriba tienes r_1, r_2 y $r_1 + r_2 = r$ y abajo tienes que $n - x, x$ y $n - x + x = n$

Ahora, abajo estamos colocando las posibles formas de escoger conjunto de n elementos de una espacio de r elementos, y arriba es la probabilidad conjunta de que primero tengamos x elementos de r_1 y $n - x$ elementos de r_2

4.4.3. Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^x \binom{r_1}{i} \binom{r_2}{n-i}$$

Idea de la Demostración:

Es por definición men :v

4.4.4. Esperanza

Esta esta muy interesante:

$$E(X) = n \left(\frac{r_1}{r} \right)$$

Demostración:

Primero que nada porque usando la definición o algo así nos van a salir cosas horribles, así que mejor empecemos por otro lado.

Sea X_i variables aleatorias de Bernoulli, tal que esten definidas por:

$$X_i = \begin{cases} 1 & \text{Al sacar el elemento i-ésimo fue de tipo } r_1 \\ 0 & \text{Al sacar el elemento i-ésimo NO fue de tipo } r_1 \end{cases}$$

Ahora, como son variables de Bernoulli, podemos encontrar bien facil su esperanza como $E(X_i) = p = \frac{r_1}{r}$

Ahora, como ya te esperabas, nota que nuestra variable aleatoria hipergeometrica es la suma de las otras $X = \sum_{i=1}^n X_i$

Ahora como la esperanza es un bonito operador lineal tenemos que:

$$\begin{aligned} E(X) &= E \left(\sum_{i=1}^n X_i \right) \\ &= \sum_{i=1}^n E(X_i) \\ &= \sum_{i=1}^n \frac{r_1}{r} \\ &= n \left(\frac{r_1}{r} \right) \end{aligned}$$

4.4.5. Varianza

Esta esta muy difícil, así que se deja para el lector :p

$$v(X) = n \left(\frac{r_1}{r} \right) \left(1 - \frac{r_1}{r} \right) \left(1 - \frac{n-1}{r-1} \right)$$

4.4.6. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = E(e^{tX}) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^{\min(n, r_1)} e^{ti} \binom{r_1}{i} \binom{r_2}{n-i}$$

4.4.7. Relación con la Binomial

Suponte que tienes una población de r elementos, con r_1 de un tipo “bueno” y $r_2 := n - r$ de un tipo “malo”.

Ahora vamos a tomar una muestra aleatoria de tamaño n , sea entonces X : Número de elementos de tipo bueno en nuestra muestra

ahora podemos tener entonces 2 posibles distribuciones dependiendo de una pregunta clave.

¿Hay reemplazo?

■ **Si es que tiene Reemplazo:**

Entonces lo que pasa es que la probabilidad de éxito es constante, por lo tanto es simplemente n experimentos de tipo Bernoulli.

La probabilidad de éxito también es bastante sencilla de sacarse, es como $p = \frac{r_1}{r}$

Por lo tanto podemos decir que:

$$X \sim B(x; n, p)$$

Es decir, tendremos (como ya sabemos como se comporta una binomial):

- $E(X) = np = \frac{nr_1}{r}$
- $v(X) = npq = \frac{nr_1}{r} \left(1 - \frac{r_1}{r}\right)$

■ **Si es que NO tiene Reemplazo:**

Entonces lo que pasa es que la probabilidad de éxito ya no es constante, de hecho, llegamos a la definición de la Hipergeométrica, es decir:

Por lo tanto podemos decir que:

$$X \sim H(x; n, r_1, r_2)$$

Es decir, tendremos (como ya sabemos como se comporta una hipergeométrica):

- $E(X) = np = \frac{nr_1}{r}$
- $v(X) = npq = \frac{nr_1}{r} \left(1 - \frac{r_1}{r}\right) \left(1 - \frac{n-1}{r-1}\right)$

Es decir, sin importar si hay o no reemplazo, el valor esperado es el mismo, pero si es que no hay reemplazos tenemos una varianza es menor.

Podemos también darnos cuenta de que mientras más población la diferencia entre el reemplazo y sin reemplazo cada vez será menor.

4.5. Poisson

Variable Aleatoria

La variable aleatoria que cuenta el número de ocurrencias en un periodo de tiempo o espacio físico dado se le llama Poisson.

X : Número de ocurrencias en un periodo de tiempo o espacio dado

Ahora, los valores posibles que puede tomar es $0, 1, 2, \dots$

Solemos entonces escribir esta distribución como:

$$X \sim P(x; \lambda)$$

donde:

- x : Nuestra variable
- λ : Es el número promedio de ocurrencias en el periodo o espacio dado

4.5.1. Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}$$

4.5.2. Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = e^{-\lambda} \sum_{i=0}^x \frac{\lambda^i}{i!}$$

Idea de la Demostración:

Es por definición men :v

4.5.3. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = e^{\lambda(e^t-1)}$$

Demostración:

Usando la función probabilidad puntual tenemos que:

$$\begin{aligned}
\Psi_X(t) &= E(e^{tX}) \\
&= \sum_{x=0}^{\infty} e^{tx} P(X = x) \\
&= \sum_{x=0}^{\infty} e^{tx} e^{-\lambda} \frac{\lambda^x}{x!} \\
&= e^{-\lambda} \sum_{x=0}^{\infty} e^{tx} \frac{\lambda^x}{x!} \\
&= e^{-\lambda} \sum_{x=0}^{\infty} \frac{(e^t \lambda)^x}{x!} \\
&= e^{-\lambda} e^{e^t \lambda} \\
&= e^{\lambda(e^t-1)}
\end{aligned}$$

4.5.4. Esperanza

Esta es muy interesante:

$$E(X) = \lambda$$

Demostración:

Esta sale o bien por definición o usando la generadora de momentos y diciendo que:

$$\begin{aligned}\Psi(t=0)' &= e^{\lambda(e^t-1)}\lambda(e^t) \Big|_{t=0} \\ &= e^0\lambda(e^0) \\ &= \lambda\end{aligned}$$

4.5.5. Varianza

Esta es muy interesante:

$$v(X) = \lambda$$

Demostración:

Esta sale o bien por definición o usando la generadora de momentos y diciendo que:

$$\begin{aligned}\Psi(t=0)'' &= e^{\lambda(e^t-1)}\lambda(e^t) + \lambda(e^t)^2 e^{\lambda(e^t-1)} \Big|_{t=0} \\ &= \lambda + \lambda^2\end{aligned}$$

Por lo tanto la varianza es $v(X) = \lambda + \lambda^2 - \lambda^2 = \lambda$

4.5.6. Relación con la Binomial

Considera $X \sim \text{Bin}(x; n, p)$, entonces cuando más grande sea n más nuestra binomial se va a parecer a una Poisson con $\lambda = np$

Demostración:

Considera $X \sim \text{Bin}(x; n, p)$, entonces esta más que claro que por ser una variable aleatoria que se distribuye con una binomial que $P(X = x) = f_X = \binom{n}{x} p^x q^{n-x}$.

Ahora como ya demostramos en las propiedades de la Poisson, vamos a suponer por un minuto que $\lambda = np$, es decir $p = \frac{\lambda}{n}$ entonces tenemos que:

$$P(X = x) = f_X = \binom{n}{x} p^x q^{n-x} = \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$$

Ahora veamos que es lo que pasa cuando tenemos una x muy muy grande, es decir:

$$\begin{aligned} \lim_{n \rightarrow \infty} P(X = x) &= \lim_{n \rightarrow \infty} \binom{n}{x} p^x q^{n-x} \\ &= \lim_{n \rightarrow \infty} \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{n!}{x!(n-x)!} \frac{\lambda^x}{n^x} \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \lim_{n \rightarrow \infty} \frac{\lambda^x}{x!} \frac{n!}{n^x (n-x)!} \left(1 - \frac{\lambda}{n}\right)^{n-x} \\ &= \frac{\lambda^x}{x!} \lim_{n \rightarrow \infty} \frac{n-x+1}{n} \dots \frac{n-1}{n} \frac{n}{n} \left(1 - \frac{\lambda}{n}\right)^n \frac{1}{(n-\lambda)^x} \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \lim_{n \rightarrow \infty} \frac{n-x+1}{n} \dots \frac{n-1}{n} \frac{n}{n} \frac{1}{(n-\lambda)^x} \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \lim_{n \rightarrow \infty} (1) \dots (1) \\ &= \frac{\lambda^x}{x!} e^{-\lambda} \end{aligned}$$

Por lo tanto cuando más grande sea n más nuestra binomial se va a parecer a una Poisson con $\lambda = np$

4.5.7. Propiedades

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim P(x_i; \lambda_i)$

Entonces $X = \sum_{i=1}^k X_i$ cumple que X se distribuye como una Poisson con parámetro $\lambda = \sum_{i=1}^k \lambda_i$

Demostración:

Sabes que para cada una de ellas tienes que $\Psi_{X_i}(t) = e^{\lambda_i(e^t - 1)}$ entonces al ser una suma de variables aleatorias tenemos que su generadora es el producto de cada generadora, es decir:

$$\begin{aligned}\Psi_X(t) &= \prod_{i=1}^k \Psi_{X_i}(t) \\ &= \prod_{i=1}^k e^{\lambda_i(e^t - 1)} \\ &= e^{(\sum_{i=1}^k \lambda_i)(e^t - 1)}\end{aligned}$$

Es decir se parece muchísimo a una Poisson con una lamda igual a $\lambda = \sum_{i=1}^k \lambda_i$

Parte III

Variables Aleatorias Continuas

Capítulo 5

Variables Aleatorias Continuas

5.1. Variables Aleatorias

Una variable aleatoria es una función que asigna a cada elemento $E_i \in S$ en el espacio muestral a un número real $X(E_i) \in \mathbb{R}$, es decir, en español, lo que hace es que es una función que nos da información de una característica de cada elemento del espacio muestral.

5.1.1. Variables Aleatorias Continuas

Las variables aleatorias cuyo conjunto de valores posibles es el de los números reales, nos permiten medir un parámetro continuo.

Recuerda que los números reales son densos, eso quiere decir que entre cuales quiera dos reales, podemos encontrar otro real entre ambos.

Obviamente se conservan practicamente todas las propiedades de cuando trabajamos con las variables aleatorias discretas.

5.2. Función Probabilidad f_X

5.2.1. Definición

Vamos a definir a la función de probabilidad de una variable aleatoria continua como aquella función $f_X(x)$ para la cual siempre se cumplan 2 cosas:

- $\int_{-\infty}^{\infty} f_X(x) dx = 1$
- $P(a < X < b) = \int_a^b f_X(x) dx$

Recuerda que las probabilidades en el caso continuo se puede ver como áreas bajo la curva delimitada según el interes.

5.2.2. Probabilidad Puntual

También se le conoce como función de probabilidad puntual. Es tecnicamente la misma que en las variables aleatorias discretas, pero al estar hablando de puede tomar cualquier real, entonces decimos que:

$$P(X = x) = 0$$

Esto nos lleva una propiedad muy importante que vamos a ocupar a cada rato:

$$P(a < X < b) = P(a < X \leq b) = P(a \leq X < b) = P(a \leq X \leq b)$$

Demostración:

- $P(a < X \leq b) = P(a < X < b) + P(b) = P(a < X < b) + 0 = P(a < X < b)$
- $P(a \leq X < b) = P(a < X < b) + P(a) = P(a < X < b) + 0 = P(a < X < b)$
- $P(a \leq X \leq b) = P(a < X < b) + P(a) + P(b) = P(a < X < b) + 0 + 0 = P(a < X < b)$

5.3. Función P. Acumulada F_X

5.3.1. Definición

Vamos a definir a la función de distribución o acumulada como:

$$F_X(x) = P(X \leq x) = \int_{-\infty}^x f_X(x)dx$$

Recuerda que las probabilidades en el caso continuo se puede ver como áreas bajo la curva delimitada según el interes.

5.3.2. Propiedades

- $f_X(x) = \frac{d F_X(x)}{dx}$ si es que tiene sentido la derivada en ese punto sino $f_X(x) = 0$

5.4. Esperanza

5.4.1. Definición

Vamos a definir a la esperanza de una variable aleatoria continua como:

$$E(x) = \mu_X = \int_{-\infty}^{\infty} x f_X(x) dx$$

5.5. Varianza

5.5.1. Definición

Vamos a definir a la varianza de una variable aleatoria continua como:

$$\begin{aligned} v(x) &= \int_{-\infty}^{\infty} (x - \mu_x)^2 f(x) dx \\ &= \left(\int_{-\infty}^{\infty} x^2 f(x) dx \right) - \mu_x^2 \end{aligned}$$

5.6. Función Generadora de Momentos

5.6.1. Definición

Vamos a definir a la esperanza de una variable aleatoria continua como:

$$\Psi_X(t) = E(e^{tX}) = \int_{-\infty}^{\infty} e^{tx} f_X(x) dx$$

Capítulo 6

Distribuciones Continuas Famosas

6.1. Uniforme

6.1.1. Definición

La mas sencilla de todas las distribuciones continuas es la uniforme.

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $a < x < b$.

Solemos entonces escribir esta distribución como:

$$X \sim U(x; a, b)$$

donde:

- a : Inicio de la muestra
- b : Fin de la muestra

6.1.2. Función Probabilidad

Esto es lo que distingue a una distribución uniforme:

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{en otro caso} \end{cases}$$

Idea de la Demostración:

La razón de que sea así es que tiene que cumplir que $\int_{-\infty}^{\infty} f(x)dx = 1$ y claro que lo cumple:

$$\begin{aligned} \int_{-\infty}^{\infty} f(x)dx &= \int_a^b \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \int_a^b dx \\ &= \frac{1}{b-a} [b-a] \\ &= 1 \end{aligned}$$

6.1.3. Función P. Acumulada

Esta es muy interesante, es:

$$F_X(x) = \frac{x-a}{b-a}$$

Idea de la Demostración:

Es por definición men :v

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f(x)dx \\ &= \int_a^x \frac{1}{b-a} dx \\ &= \frac{1}{b-a} \int_a^x dx \\ &= \frac{x-a}{b-a} \end{aligned}$$

6.1.4. Esperanza

Esta es muy interesante:

$$E(X) = \frac{a+b}{2}$$

Demostración:

Esta también sale bonita:

$$\begin{aligned} E(X) &= \int_{-\infty}^{\infty} x f_X(x) dx \\ &= \int_a^b x \frac{1}{b-a} dx \\ &= \left(\frac{1}{b-a} \right) \int_a^b x dx \\ &= \left(\frac{1}{b-a} \right) \frac{b^2 - a^2}{2} \\ &= \left(\frac{1}{b-a} \right) \frac{(b-a)(b+a)}{2} \\ &= \frac{a+b}{2} \end{aligned}$$

6.1.5. Varianza

Esta esta muy difícil, pero si se puede:

$$v(X) = \frac{(a-b)^2}{12}$$

Demostración:

Primero hay que hacer que:

$$\begin{aligned} E(X^2) &= \int_{-\infty}^{\infty} x^2 f_X(x) dx \\ &= \int_a^b x^2 \frac{1}{b-a} dx \\ &= \left(\frac{1}{b-a} \right) \int_a^b x^2 dx \\ &= \left(\frac{1}{b-a} \right) \frac{b^3 - a^3}{3} \\ &= \left(\frac{1}{b-a} \right) \frac{(b-a)(b^2 + ab + a^2)}{3} \\ &= \frac{b^2 + ab + a^2}{3} \end{aligned}$$

Ahora podemos sacar a la varianza:

$$\begin{aligned} v(X) &= E(X^2) - \mu_X^2 \\ &= E(X^2) - \frac{(a+b)^2}{4} \\ &= \frac{b^2 + ab + a^2}{3} - \frac{a^2 + 2ab + b^2}{4} \\ &= \frac{4b^2 + 4ab + 4a^2}{12} - \frac{3a^2 + 6ab + 3b^2}{12} \\ &= \frac{a^2 + b^2 - 2ab}{12} \\ &= \frac{(a-b)^2}{12} \end{aligned}$$

6.1.6. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = \frac{e^{bt} - e^{at}}{t(b-a)}$$

Demostración:

Ahora vamos a demostrarlo:

$$\begin{aligned} E(e^{tX}) &= \int_{-\infty}^{\infty} e^{tx} f_X(x) dx \\ &= \left(\frac{1}{b-a} \right) \int_a^b e^{tx} dx \\ &= \left(\frac{1}{b-a} \right) \frac{e^{bt} - e^{at}}{t} \\ &= \frac{e^{bt} - e^{at}}{t(b-a)} \end{aligned}$$

6.2. Exponencial

6.2.1. Definición

Se utiliza generalmente para representar una distribución del tiempo que transcurre antes de la ocurrencia de un suceso.

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $x > 0$

Solemos entonces escribir esta distribución como:

$$X \sim E(x; \beta)$$

donde:

- β : Es un parámetro que tiene que ser un entero positivo

6.2.2. Función Probabilidad

Esto es lo que distingue a una distribución exponencial:

$$f_X(x) = \begin{cases} \beta e^{-\beta x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

6.2.3. Función P. Acumulada

Esta es muy interesante, es:

$$F_X(x) = 1 - e^{-\beta x}$$

Idea de la Demostración:

Es por definición men :v

$$\begin{aligned} F_X(x) &= \int_{-\infty}^x f(t) dt \\ &= \int_0^x \beta e^{-\beta t} dt \\ &= -e^{-\beta t} \Big|_0^x \\ &= 1 - e^{-\beta x} \end{aligned}$$

6.2.4. Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = \frac{\beta}{\beta - t}$$

Demostración:

Ahora vamos a demostrarlo:

$$\begin{aligned} E(e^{tX}) &= \int_{-\infty}^{\infty} e^{tx} f_X(x) dx \\ &= \int_0^{\infty} e^{tx} \beta e^{-\beta x} dx \\ &= \beta \int_0^{\infty} e^{(t-\beta)x} dx \\ &= \beta \frac{1}{t-\beta} e^{(t-\beta)x} \Big|_0^{\infty} \\ &= \beta \frac{1}{t-\beta} (-1) \\ &= \frac{\beta}{\beta - t} \end{aligned}$$

6.2.5. Esperanza

Esta esta muy interesante:

$$E(X) = \frac{1}{\beta}$$

Demostración:

Esta también sale bonita:

$$\begin{aligned} E(X) &= \Psi'_X(0) \\ &= \frac{d}{dx} t \frac{\beta}{\beta - t} \Big|_0 \\ &= \frac{\beta}{(\beta - t)^2} \Big|_0 \\ &= \frac{\beta}{(\beta)^2} \\ &= \frac{1}{\beta} \end{aligned}$$

6.2.6. Varianza

Esta esta muy difícil, pero si se puede:

$$v(X) = \frac{1}{\beta^2}$$

Demostración:

$$\begin{aligned} E(X^2) &= \Psi_X''(0) \\ &= \frac{d}{dx} \frac{\beta}{(\beta - t)^2} \Big|_0 \\ &= \frac{2\beta}{(\beta - t)^3} \Big|_0 \\ &= \frac{2\beta}{(\beta)^3} \\ &= \frac{2}{\beta^2} \end{aligned}$$

Entonces la varianza sale rapido:

$$\begin{aligned} v(X) &= E(X^2) - \mu_X^2 \\ &= \frac{2}{\beta^2} - \frac{1}{\beta^2} \\ &= \frac{1}{\beta^2} \end{aligned}$$

6.2.7. Propiedades

- Podemos decir que esta distribución no tiene memoria, me explico mejor.

Sea $P(X > a + b \mid X > a) = P(X > b)$ con a, b un naturales positivos

Demostración:

$$\begin{aligned}
 P(X > a + b \mid X > a) &= \frac{P(X > a + b \text{ y } X > a)}{P(X > a)} \\
 &= \frac{P(X > a + b)}{P(X > b)} \\
 &= \frac{1 - F_X(a + b)}{1 - F_X(b)} \\
 &= \frac{e^{-a\beta - b\beta}}{e^{-b\beta}} \\
 &= e^{-b\beta}
 \end{aligned}$$

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim E(x_i; \beta)$

Entonces $X = \min(X_1, X_2, \dots, X_k)$ también cumple que X se distribuye como una Exponencial con parámetro $\beta = n\beta$

Demostración:

Esa sale rápido:

$$\begin{aligned}
 P(X > t) &= P(X_1 > t)P(X_2 > t) \dots (X_k > t) \\
 &= e^{-t\beta} \dots e^{-t\beta} \\
 &= e^{-t(n\beta)}
 \end{aligned}$$

Es decir se parece muchísimo a una Exponencial con una beta igual a $\beta = n\beta$

- Sea $X_1, X_2, \dots, X_\alpha$ variables aleatorias independientes y $X_i \sim E(x_i; \beta)$

Entonces $X = X_1 + X_2 + \dots + X_\alpha$ se destruye como como $X \sim \Gamma(x; \alpha, \beta)$

Demostración:

Nota que:

$$\Psi_{X_i}(t) = \frac{\beta}{\beta - t}$$

Entonces tenemos que:

$$\begin{aligned}
 \Psi_X(t) &= \prod_{i=1}^{\alpha} \frac{\beta}{\beta - t} \\
 &= \left(\frac{\beta}{\beta - t} \right)^\alpha
 \end{aligned}$$

Es decir, es una función generadora de la gamma, y ya :v

6.3. Gamma

6.3.1. Función Gamma

La función Gamma se puede ver para $a > 0$ como:

$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx$$

Propiedades

La función gamma tiene un par de propiedades interesantes

■ $\Gamma(1) = 1$

Demostración:

Nota que:

$$\begin{aligned} \Gamma(1) &= \int_0^{\infty} x^{1-1} e^{-x} dx \\ &= \int_0^{\infty} e^{-x} dx \\ &= -e^{-x} \Big|_0^{\infty} \\ &= e^0 - 0 \\ &= 1 \end{aligned}$$

■ $\Gamma(a) = (a-1)\Gamma(a-1)$

Demostración:

Esto es clave:

$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx$$

Esta se puede intentar resolver por partes, entonces tenemos que:

- $u = x^{a-1}$
- $du = (a-1)x^{a-2} dx$
- $dv = e^{-x}$
- $v = -e^{-x}$

Entonces decimos que:

$$\begin{aligned} \Gamma(a) &= \int_0^{\infty} x^{a-1} e^{-x} dx \\ &= -x^{a-1} e^{-x} \Big|_0^{\infty} + \int_0^{\infty} e^{-x} (a-1)x^{a-2} dx \\ &= \Gamma(a) = (a-1)\Gamma(a-1) \end{aligned}$$

- Si $n \in \mathbb{Z}^+$ entonces $\Gamma(n) = (n-1)!$

Demostración:

Es simplemente recursividad es decir:

$$\begin{aligned}\Gamma(n) &= (n-1)\Gamma(n-2) \\ &= (n-1)(n-2)\Gamma(n-3) \\ &= \dots \\ &= (n-1)!\end{aligned}$$

6.3.2. Definición

Se utiliza generalmente para representar una distribución del tiempo que transcurre antes de la ocurrencia de un suceso.

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $x > 0$

Solemos entonces escribir esta distribución como:

$$X \sim \Gamma(x; a, \beta)$$

donde:

- a : Entero positivo
- β : Es un parámetro que tiene que ser un entero positivo

6.3.3. Función Probabilidad

Esto es lo que distingue a una distribución gamma:

$$f_X(x) = \begin{cases} \frac{\beta^a}{\Gamma(a)} x^{a-1} e^{-\beta x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

6.3.4. Función Acumulada

Esta esta rara, pero ve que.

$$F_X(x) = 1 - F_X^P(\alpha - 1) \quad \text{Con } \lambda = \beta x$$

Es decir:

$$F_X(x) = 1 - e^{-\beta x} \sum_{i=0}^{\alpha-1} \frac{(\beta x)^i}{i!}$$

Demostración:

Esta esta bien genial: Primero veamos que lo que queremos sacar es:

$$P(X \geq x) = \frac{\beta^\alpha}{\Gamma(x)} \int_x^\infty x^{\alpha-1} e^{-\beta x} dx$$

Ahora hay que notar al patrón que sale de hacer por partes:

$$\begin{aligned} P(X \geq x) &= \frac{\beta^\alpha}{\Gamma(x)} \int_x^\infty x^{\alpha-1} e^{-\beta x} dx \\ &= \frac{(\beta x)^{\alpha-1}}{\Gamma(\alpha-1)!} e^{-\beta x} + \frac{(\beta x)^{\alpha-2}}{\Gamma(\alpha-2)!} e^{-\beta x} + \frac{(\beta x)^{\alpha-3}}{\Gamma(\alpha-3)!} e^{-\beta x} + \dots \end{aligned}$$

Ahora ve que α es un entero positivo

Por lo tanto tenemos que:

$$P(X \geq x) = \sum_{i=0}^{\alpha} -1 \frac{(\beta x)^i}{\Gamma(i)!} e^{-\beta x}$$

Nota que esto no es más que una Poisson, más explícitamente tenemos que:

$$\sum_{i=0}^{\alpha} -1 \frac{(\beta x)^i}{\Gamma(i)!} e^{-\beta x} = F_X^P(\alpha - 1)$$

Entonces nos damos cuenta al final que:

$$F_X(x) = 1 - P(X \geq x) = 1 - F_X^P(\alpha - 1)$$

Donde tenemos que $\alpha = \beta x$

6.3.5. Generadora de Momentos

Esto es sencillo:

$$\Psi_X(t) = \left(\frac{\beta}{\beta - t} \right)^\alpha$$

Demostración:

$$\begin{aligned} \Psi_X(t) &= E(e^{tX}) \\ &= \frac{\beta^n}{\Gamma^n} \int_{-\infty}^{\infty} e^{tx} x^{\alpha-1} e^{-\beta x} dx \\ &= \frac{\beta^n}{\Gamma^n} \int_{-\infty}^{\infty} e^{-x(\beta-t)} x^{\alpha-1} dx \end{aligned}$$

Ahora vemos que: $x = \frac{u}{\beta-t}$ $u = [\beta - t]x \rightarrow du = [\beta - t]dx$ to $dx = \frac{du}{\beta-t}$

Ahora vemos que:

$$\begin{aligned} \Psi_X(t) &= \frac{\beta^n}{\Gamma^n} \int_{-\infty}^{\infty} \left[\frac{u}{\beta-t} \right]^{\alpha-1} e^{-u} \frac{du}{\beta-t} \\ &= \frac{\beta^\alpha}{(\beta-t)^\alpha \Gamma(\alpha)} \int_0^\infty u^{\alpha-1} e^{-u} du \\ &= \frac{\beta^\alpha}{(\beta-t)^\alpha} \\ &= \left(\frac{\beta}{\beta-t} \right)^\alpha \end{aligned}$$

6.3.6. Esperanza

Usando la función generadora tenemos que:

$$E(X) = \frac{\alpha}{\beta}$$

Demostración:

$$\begin{aligned} E(X) &= \Psi'_X(0) \\ &= \frac{d}{dx} t \left[\frac{\beta}{\beta - t} \right]^\alpha \Big|_{t=0} \\ &= \beta^\alpha \frac{d}{dx} t (\beta - t)^{-\alpha} \Big|_{t=0} \\ &= \beta^\alpha \alpha (\beta - t)^{-\alpha-1} \Big|_{t=0} \\ &= \beta^\alpha \alpha \beta^{-\alpha-1} \\ &= \frac{\alpha}{\beta} \end{aligned}$$

6.3.7. Varianza

Usando la función generadora tenemos que:

$$v(X) = \frac{\alpha}{\beta^2}$$

Demostración:

$$\begin{aligned} E(X^2) &= \Psi'_X(0) \\ &= \beta^\alpha \alpha \frac{d}{dx} t [\beta - t]^{-\alpha-1} \Big|_{t=0} \\ &= \beta^\alpha \alpha (-\alpha - 1) \frac{d}{dx} t [\beta - t]^{-\alpha-2} (-1) \Big|_{t=0} \\ &= \beta^\alpha \alpha (\alpha + 1) \frac{d}{dx} t [\beta - t]^{-\alpha-2} \Big|_{t=0} \\ &= \beta^\alpha \alpha (\alpha + 1) \beta^{-2} \\ &= \frac{\alpha(\alpha + 1)}{\beta^2} \end{aligned}$$

Por lo tanto finalmente tenemos que:

$$\begin{aligned} v(X) &= E(X^2) - E(X)^2 \\ &= \frac{\alpha(\alpha + 1)}{\beta^2} - \left(\frac{\alpha}{\beta} \right)^2 \\ &= \frac{\alpha}{\beta^2} \end{aligned}$$

6.3.8. Propiedades

- Si tenemos una distribución Gamma pero donde $\alpha = 1$, entonces lo que en realidad tenemos es una distribución exponencial con la misma β
- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim \Gamma(x_i; \alpha_i, \beta)$
Entonces $X = X_1 + X_2 + \dots + X_k$ se destruye como como $X \sim \Gamma(x; \sum_{i=1}^k \alpha_i, \beta)$

Demostración:

Nota que:

$$\Psi_{X_i}(t) = \left(\frac{\beta}{\beta - t} \right)^\alpha$$

Entonces tenemos que:

$$\begin{aligned} \Psi_X(t) &= \prod_{i=1}^k \left(\frac{\beta}{\beta - t} \right)^{\alpha_i} \\ &= \left(\frac{\beta}{\beta - t} \right)^{\sum_{i=1}^k \alpha_i} \end{aligned}$$

Es decir, es una función generadora de la gamma, y ya :v

6.4. Normal

6.4.1. Definición

Es la más famosa de todas las continuas, es simétrica con respecto al valor central μ

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria son todos los reales

Solemos entonces escribir esta distribución como:

$$X \sim N(x; \mu, \sigma^2)$$

donde:

- μ : El valor central, es cualquier real
- σ^2 : La varianza, es un real positivo

Nota que si pasa que $X \sim N(x; \mu = 0, \sigma^2 = 1)$ entonces se suele denotar como:
 $Z \sim N(0, 1)$

Se le conoce como normal estandar.

6.4.2. Estandarización

Ya que tenemos una normal estandar, es decir una que cumple que $\mu = 0, \sigma^2 = 1$

Ahora, hay una forma muy fácil de “estandarizar” es decir de transformar cualquier punto sobre una normal a ese punto en la estandar esta dada por:

$$Z = \frac{X - \mu}{\sigma}$$

Demostración:

Lo que hacemos es primero sacar la distancia al punto central, una vez que lo tengamos lo que hacemos es dividir entre la desviación estandar porque es una nueva escala una que nunca cambia.

Y obviamente tiene su inversa:

$$X = Z\sigma + \mu$$

6.4.3. Función Probabilidad

Esto es lo que distingue a una distribución uniforme:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Demostración que es una función de Probabilidad:

Supon que $I = \int_{-\infty}^{\infty} f_X(x)dx$, por lo tanto basta con hacer demostrar que $I^2 = 1$.

Primero haremos el cambio de variable a $u = \frac{x-\mu}{\sigma}$ y $du = \frac{dx}{\sigma}$, es decir, vamos a mejor resolver la estandar:

$$I = \int_{-\infty}^{\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}u^2} du$$

Entonces decimos ahora que:

$$I^2 = \frac{1}{2\pi} \left(\int_{-\infty}^{\infty} e^{-\frac{1}{2}u^2} du \right)^2 \quad (6.1)$$

$$= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(u^2+v^2)} dudv \quad (6.2)$$

Ahora simplemente cambiamos a coordenada polares:

$$I^2 = \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(u^2+v^2)} dudv \quad (6.3)$$

$$= \frac{1}{2\pi} \int_0^{2\pi} \int_0^{\infty} e^{-\frac{r^2}{2}} r dr d\theta \quad (6.4)$$

$$= \frac{1}{2\pi} \int_0^{2\pi} \left[-e^{-\frac{r^2}{2}} \Big|_0^{\infty} \right] d\theta \quad (6.5)$$

$$= \frac{1}{2\pi} \int_0^{2\pi} d\theta \quad (6.6)$$

$$= \frac{1}{2\pi} \theta \Big|_0^{2\pi} \quad (6.7)$$

$$= 1 \quad (6.8)$$

6.4.4. Generadora de Momentos

Esta es sencilla:

$$\Psi_X(t) = e^{t\mu + \frac{1}{2}(t^2\sigma^2)}$$

Demostración:

Hagamos la definición:

$\Psi_X(t) = \int_{-\infty}^{\infty} e^{tx} f_x dx$	Por definición
$= \int_{-\infty}^{\infty} e^{tx} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx$	Definición igual :v
$= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{t(\mu+\sigma u) - \frac{1}{2}u^2} du$	La hacemos estandar $u = \frac{x-\mu}{\sigma}$ y $du = \frac{dx}{\sigma}$
$= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{t\mu} e^{-\frac{1}{2}(u^2 - 2t\sigma u)} du$	Ponemos bonito
$= \frac{e^{t\mu}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(u^2 - 2t\sigma u + (t^2\sigma^2) - (t^2\sigma^2))} du$	Ponemos bonito
$= \frac{e^{t\mu + \frac{1}{2}(t^2\sigma^2)}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(u^2 - 2t\sigma u + (t^2\sigma^2))} du$	Completamos el cuadrado
$= \frac{e^{t\mu + \frac{1}{2}(t^2\sigma^2)}}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{1}{2}(z)^2} dz$	$z = u - t\sigma \quad dz = du$
$= e^{t\mu + \frac{1}{2}(t^2\sigma^2)} \int_{-\infty}^{\infty} \sqrt{2\pi} e^{-\frac{1}{2}(z)^2} dz$	Acomodo para hacer una normal estandar
$= e^{t\mu + \frac{1}{2}(t^2\sigma^2)}$	Recuerda que por ser función de probabilidad

6.4.5. Media

Mira, que loco :v

$$E(X) = \mu$$

Demostración:

Mira, que bonito es todo:

$$\begin{aligned}
E(X) &= \Psi_X(0)' \\
&= e^{t\mu + \frac{1}{2}(t^2\sigma^2)} \left[\mu + \frac{2t\sigma^2}{2} \right] \Big|_0 \\
&= e^0(\mu) \\
&= \mu
\end{aligned}$$

6.4.6. Varianza

Mira, que loco :v

$$v(X) = \sigma^2$$

Demostración:

Mira, que bonito es todo:

$$\begin{aligned}
v(X) &= E(X^2) - \mu^2 \\
&= \Psi_X(0)'' - \mu^2 \\
&= \mu^2 + \sigma^2 - \mu^2 \\
&= \sigma^2
\end{aligned}$$

6.4.7. Propiedades

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim N(x_i; \mu_i, \sigma_i^2)$
Entonces $X = X_1 + X_2 + \dots + X_k$ se destruye como como $X \sim N(x_i; \sum_{i=1}^k \mu_i, \sum_{i=1}^k \sigma_i^2)$

Demostración:

Empecemos por ver que $X_i \sim N(x; \mu_i, \sigma_i^2)$ Es decir $\Psi_{X_i}(t) = e^{t\mu_i + \frac{1}{2}(t^2\sigma_i^2)}$ entonces vemos que:

$$\begin{aligned}\Psi_X(t) &= \Psi_{\sum_{i=1}^n X_i}(t) \\ &= \prod_{i=1}^n \Psi_{X_i}(t) \\ &= e^{\sum_{i=1}^n t\mu_i + \frac{1}{2}(t^2\sigma_i^2)} \\ &= e^{t(\sum_{i=1}^n \mu_i) + \frac{1}{2}(t^2(\sum_{i=1}^n \sigma_i^2))}\end{aligned}$$

Por lo tanto como puedes ver tiene una media de $\mu_X = \sum_{i=1}^n \mu_i$ y una varianza de $\sigma_X^2 = \sum_{i=1}^n \sigma_i^2$

- Sea $X_i \sim N(x_i; \mu, \sigma^2)$

Entonces $Y = aX + b$ se destruye como como $Y \sim N(y; a\mu + b, a\sigma^2)$

Demostración:

Empecemos por ver que $X \sim N(x; \mu, \sigma^2)$ entonces vemos que:

$$\begin{aligned}\Psi_Y(t) &= E(e^{tY}) \\ &= E(e^{t(aX+b)}) \\ &= e^{tb} E(e^{taX}) \\ &= e^{tb} \Psi_X(at) \\ &= e^{tb} e^{at\mu + \frac{1}{2}a^2t^2\sigma^2} \\ &= e^{t(b+a\mu) + \frac{1}{2}a^2t^2\sigma^2}\end{aligned}$$

Por lo tanto como puedes ver tiene una media de $\mu_Y = a\mu + b$ y una varianza de $\sigma_Y^2 = a^2\sigma^2$

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim N(x_i; \mu, \sigma^2)$

Entonces $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ se destruye como como $\bar{X} \sim N(\bar{x}; \mu, \frac{\sigma^2}{n})$

Demostración:

Colorario joven, es un colorario :v

Capítulo 7

Probabilidad Hardcore

7.1. Teorema Central del Límite

7.1.1. Definición

Garantiza que para n (tamaño de muestra) suficientemente grande ($n \geq 30$) entonces:

- Si tienes una variable aleatoria que es la media muestral de otras variables aleatorias entonces mientras mas variables aleatoria muestrees entonces más se va aproximar:

$$\bar{X} \approx N(x; \mu = \mu, \sigma^2 = \frac{\sigma^2}{n})$$

- Si tienes una variable aleatoria que esta compuesta por la suma de muchas otras variables aleatorias entonces mientras mas grande sea la cantidad de variables aleatorias más se aproxima a una normal:

$$\sum_{i=0}^n X_i \approx N(x; \mu_x = n\mu, \sigma_x^2 = n\sigma^2)$$

7.2. Teorema Central de Chebyshev

7.2.1. Definición

Si no se conoce la distribución de la variable aleatoria, pero por circunstancias raras tengamos la media y la varianza entonces podemos conocer información de la variable.

Tenemos que:

$$P(\mu - k\sigma \leq X \leq \mu + k\sigma) \geq 1 - \frac{1}{k^2}$$

$$P(|X - \mu| \leq k\sigma) \geq 1 - \frac{1}{k^2}$$

$$P(|X - \mu| > k\sigma) < \frac{1}{k^2}$$

Parte IV

Probabilidades Conjuntas

Capítulo 8

Variables A. Multidimensionales

8.1. Función de Probabilidad

La función de probabilidad conjunta de una variable bidimensional se puede ver de dos maneras:

8.1.1. Discreto

La definimos como:

$$f_{X,Y}(x, y) := P(X = x, Y = y)$$

Y cumple con que:

- $P(X = x, Y = y) \in [0, 1]$
- $\sum_y \sum_x P(X = x, Y = y) = 1$

8.1.2. Continuo

Es la función de dos variables que cumple que:

- $f_{X,Y}(x, y) > 0 \forall x, y$
- $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy dx = 1$

Ahora en el rango de los posibles valores de la variable aleatoria bidimensional en el caso de continuo serán regiones en el plano y las probabilidades de interés serán volúmenes bajo la curva de interés.

8.2. Distribución Acumulada

8.2.1. Discreto

La definimos como:

$$F_{X,Y} := P(X \leq x, Y \leq y)$$

8.2.2. Continuo

La definimos como:

$$F_{X,Y} := \int_{-\infty}^y \int_{-\infty}^x f_{X,Y}(x, y) dx dy$$

Nota que $\frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y) = f_{X,Y}(x, y)$

8.3. Distribución Marginal

8.3.1. Discreto

La definimos de 2 maneras:

$$\blacksquare f_X(x) := \sum_y P(X = x, Y = y)$$

$$\blacksquare f_Y(y) := \sum_x P(X = x, Y = y)$$

8.3.2. Continuo

$$\blacksquare f_X(x) := \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy$$

$$\blacksquare f_Y(y) := \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx$$

8.4. Distribución Condicional

8.4.1. Discreto

Podemos definirlo como:

$$f_{X|Y}(x|y) = \frac{P(X = x, Y = y)}{P(Y = y)} \quad \forall x$$

Sus valores posibles son los valores de la variable aleatoria X .

Tenemos una distribución diferente para cada valor de Y

8.4.2. Continuo

Podemos definirlo como:

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

Sus valores posibles son los valores de la variable aleatoria X .

Tenemos una distribución diferente para cada valor de Y

8.5. Independencia de Variables

Sea una variable aleatoria dimensional X, Y , son independientes si y solo si:

$$P(X = x, Y = y) = P(X = x)P(Y = y)$$

O dicho en otras palabras:

$$f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

8.5.1. Propiedades

- X, Y son linealmente independientes si y solo si $P(X = x|Y = y) = P(X = x)$ o dicho de otra manera si $f_{X|Y}(x, y) = f_X(x)$

Parte V

Estimaciones

Capítulo 9

Estimadores Puntuales

9.1. Características

9.1.1. Insesgado

Sesgo

Este esta dado por:

$$Sesgo(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Definición

Suponte que tenemos un estimador puntual $\hat{\theta}$, decimos que es insesgado si y solo si $E(\hat{\theta}) = \theta$

9.1.2. Varianza Mínima

Antes que nada vayamos con las definiciones:

Error Cuadrático Medio

Este esta dado por:

$$ECM(\hat{\theta}) = E(\theta - \hat{\theta})^2$$

Podemos trabar un poco la definición y llegar a una alternativa que puede sernos mucho más útil

$$ECM(\hat{\theta}) = V(\hat{\theta}) + Sesgo(\hat{\theta})$$

Si tenemos un estimador insesgado entonces es más que obvio que:

$$ECM(\hat{\theta}) = V(\hat{\theta})$$

9.1.3. Optimo

Decimos que un estimador es optimo si cumple que:

$$ECM(\hat{\theta}) < ECM(\hat{\theta}_x) \forall \theta_x$$

9.1.4. Optimo

Decimos que un estimador es consistente si cumple que siendo n el tamaño de la muestra:

$$\lim_{n \rightarrow \infty} ECM(\hat{\theta}) = 0$$

9.2. Método de los Momentos

Podemos usar los momentos para estimar parámetros, de la siguiente manera:

- El k-ésimo momento poblacional es $\mu_k = E(X^K)$
- El k-ésimo momento muestral es $\mu_k = \frac{1}{n} \sum_{i=1}^n X_i^K$

Ahora solo decimos que $\mu_k = m_k$ y listo.

Recuerda para este paso que $E(X^2) = E(X)^2 + v(X)$

9.3. Método de Máxima Verosimilitud

Ok, este parece que se ve un poco más difícil de explicar pero es igual de sencillo.

Si tenemos una muestra aleatoria de n de una población con una función de probabilidad de $f(x; \theta)$ entonces tenemos que la función de verosimilitud esta dada por:

$$\begin{aligned} L(\theta) &= f(x_1; \theta) f(x_2; \theta) \dots f(x_n; \theta) \\ &= \prod_{i=1}^n f(x_i; \theta) \end{aligned}$$

Ahora lo único que tenemos que hacer es encontrar la θ tal que esta función se maximice.

Ahora, generalmente al estar hablando del producto de funciones lo que se suele hacer es encontrar el máximo de $Ln(L(\theta))$, pues tienen los mismo máximos y es generalmente más sencillos de encontrar.

Ahora, después de derivar con respecto a lo que tu quieras e igualar a cero, lo único que tienes que hacer es despejar lo que tu quieres.

Parte VI

CheatSheet - Formulario

Capítulo 10

CheatSheet - Formulario

10.1. Teoría de Conjuntos

Nombre	Propiedad
Operaciones Básicas	
Complemento	$A' = \{ x \mid x \notin X \}$
Intersección	$A \cap B = \{ x \mid x \in A \text{ y } x \in B \}$
Unión	$A \cup B = \{ x \mid x \in A \text{ ó } x \in B \}$
Leyes de Morgan	
Morgan sobre Unión	$(A \cup B)' = A' \cap B'$
Morgan sobre Intersección	$(A \cap B)' = A' \cup B'$
Combinatoria	
Complemento	$A' = \{ x \mid x \notin X \}$
Intersección	$A \cap B = \{ x \mid x \in A \text{ y } x \in B \}$
Unión	$A \cup B = \{ x \mid x \in A \text{ ó } x \in B \}$

10.2. Combinatoria

- Número de **permutaciones** de un conjunto de n objetos

$$n!$$

- Número de **muestras ordenadas** de tamaño r **con remplazo** de un conjunto de n objetos

$$n^r$$

- Número de **muestras ordenadas** de tamaño r **sin remplazo** de un conjunto de n objetos

$${}_nP_r = \frac{n!}{(n-r)!} = (n)(n-1)(n-2) \dots (n-r+1)$$

- Número de **muestras no ordenadas** de tamaño r **sin remplazo** de un conjunto de n objetos

Esto es lo mismo que el número de subconjuntos de cardinalidad r de un conjunto de n elementos

$$\binom{n}{r} = {}_nC_r = \frac{{}_nP_r}{r!} = \frac{n!}{r!(n-r)!} = \frac{(n)(n-1)(n-2) \dots (n-r+1)}{r!}$$

- Número de subconjuntos de un conjunto de n elementos:

$$2^n$$

item Las formas de permutar n elementos en un círculo es:

$$(n-1)!$$

10.2.1. Propiedades Coeficientes Binomiales

- Propiedades Simétricas

$$\binom{n}{k} = \binom{n}{n-k}$$

- Casos Especiales

$$\binom{n}{0} = \binom{n}{n} = 1 \qquad \binom{n}{1} = \binom{n}{n-1} = n$$

- Teorema del Binomio

$$(x+y)^n = \sum_{k=0}^n \binom{n}{k} x^k y^{n-k}$$

- Teorema del Binomio (Caso Especial)

$$\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = 1$$

10.3. Probabilidad Básica

Definimos la probabilidad de un evento A como:

$$P(A) = \frac{|A|}{|S|} \quad \text{Recuerda que } A \text{ es un evento y } S \text{ es espacio muestral}$$

10.3.1. Propiedades

- $P(S) = 1$
- Si A_1, A_2, \dots, A_n son eventos mutuamente excluyentes entonces:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i)$$

- $P(\emptyset) = 0$
- $P(A') = 1 - P(A)$
- Si $A \subseteq B$ entonces $P(A) \leq P(B)$
- La probabilidad de la unión de n eventos se puede escribir de manera general como:

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{i < j} P(A_i A_j) + \sum_{i < j < k} P(A_i A_j A_k) + \dots + (-1)^{n+1} P\left(\bigcap_{i=1}^n A_i\right)$$

- Por consecuencia del caso general tenemos que:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- Por consecuencia del caso general tenemos que:

$$\begin{aligned} P(A \cup B \cup C) = & P(A) + P(B) + P(C) \\ & - (P(A \cap B) + P(A \cap C) + P(B \cap C)) \\ & + P(A \cap B \cap C) \end{aligned}$$

- $P(A - B) = P(A) - P(A \cap B)$

10.4. Probabilidad Condicional

La probabilidad de que ocurra el Evento A conociendo que ya paso el Evento B se denota y define como:

$$P(A \mid B) := \frac{P(A \cap B)}{P(B)} = \frac{|A \cap B|}{|B|}$$

10.4.1. Propiedades

■ Conservamos Propiedades

La propiedad condicional cumple las propiedades que ya vimos de una propiedad de un evento cualquiera, pero ahora el espacio muestral que antes era S se ha reducido.

- $P(A \mid B) + P(A' \mid B) = 1$
- $P(A \cup B \mid C) = P(A \mid C) + P(B \mid C) - P(A \cap B \mid C)$

■ Definición Alternativa

Podemos redefinir a la probabilidad condicional como: $P(A \mid B) = \frac{|A \cap B|}{|B|}$

■ Regla de Multiplicación

Podemos escribir a $P(A \cap B)$ en terminos de probabilidad condicional.

$$P(A \cap B) = P(A|B) P(B) = P(B|A) P(A)$$

10.5. Eventos Independientes

Dados 2 eventos que A, B son Independientes si y solo si $P(A) = P(A|B)$ y se escribe: $A \perp B$.

10.5.1. Propiedades

- Si $A \perp B$ entonces $P(A \cap B) = P(A)P(B)$
- Si $A \perp B$ entonces $A' \perp B'$
- Si $A \perp B$ entonces $P(A \cap B) \neq 0$
- Si $P(A \cap B) = 0$ entonces A, B no son eventos independientes

10.5.2. Teorema de Bayes

Considera un conjunto de eventos $\{A_1, \dots, A_n\}$ mutuamente excluyentes y tales que $\bigcup_{i=1}^n A_i = S$, es decir son particiones de S .

Entonces podemos escribir la probabilidad de un evento B donde $B \subset S$ como:

$$P(B) = \sum_{i=1}^n P(B|A_i) P(A_i)$$

Gracias a esto podemos decir que:

$$\begin{aligned} P(A_i|B) &= \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{P(B|A_i) P(A_i)}{\sum_{i=1}^n P(A_i) P(B|A_i)} \end{aligned}$$

10.6. Variables Aleatorias Discretas

10.6.1. Función Probabilidad f_X

Propiedades

Es una función de probabilidad, es decir tiene que cumplir que la suma de todos los posibles valores de la variable aleatoria den uno.

Más formalmente tenemos que la función probabilidad es aquella función que cumple que:

- $\forall a \in \mathbb{R} \quad 0 \leq f_X(a) \leq 1$
- $\{ x \mid f_X(x) \neq 0 \}$ es un conjunto finito o numerable
- $\sum_x f_X(x) = 1$

10.6.2. Función P. Acumulada F_X

Definición

Describimos a la función de probabilidad acumulada como:

$$F_X(x) = \sum_{i \leq x} f_X(i)$$

Propiedades

- Una característica muy común es que:
 - $\lim_{x \rightarrow -\infty} F_X(x) = 0$
 - $\lim_{x \rightarrow \infty} F_X(x) = 1$
- Si $x_1 \leq x_2$ entonces $F_X(x_1) \leq F_X(x_2)$

Función Fundamental

Podemos ver a la acumulada como una función fundamental, tal que podemos escribir a todas las demás:

- $P(X = x) = F_X(x) - F_X(x - 1)$
- $P(X < x) = F_X(x - 1)$
- $P(X \leq x) = F_X(x)$
- $P(X > x) = 1 - F_X(x)$
- $P(X \geq x) = 1 - F_X(x - 1)$
- $P(a \leq X \leq b) = F_X(b) - F_X(a - 1)$
- $P(a < X \leq b) = F_X(b) - F_X(a)$
- $P(a \leq X < b) = F_X(b - 1) - F_X(a)$
- $P(a < X < b) = F_X(b - 1) - F_X(a - 1)$

10.6.3. Esperanza o Media

Definición

Decimos que el valor esperado, esperanza ó media de la variable X se define como:

$$\mu_X = E(X) = \sum_x x f_X(x) = \sum_x x P(X = x)$$

Propiedades

- Si X puede tomar un número infinito de valores entonces la esperanza de X existe si y solo si $\sum_x |x| f_X(x) < \infty$

- Podemos dar una definición al evaluar la esperanza sobre una función:

$$E(g(x)) = \sum_x g(x) f_X(x)$$

- Es un Operador Lineal, es decir:

$$E(\alpha X + \beta Y) = \alpha E(X) + \beta E(Y)$$

- Si X, Y son independientes entonces:

$$E(XY) = E(X)E(Y)$$

- Si a es una constante, entonces:

$$E(a) = a$$

10.6.4. Varianza

Definición

Decimos que la varianza de la variable X con $f_X(x)$ se define como:

$$v(X) = E((X - \mu)^2)$$

Desviación Estandar

Decimos que la desviación estandar de la variable X con $f_X(x)$ se define como:

$$\sigma(X) = \sqrt{v(X)}$$

Se usa generalmente por las unidades que tiene la varianza, nada mas

Propiedades

- $v(X) = E(X^2) - (E(X))^2$
- $V(a) = 0$
- $v(aX) = a^2v(X)$
- $v(X + Y) = v(X) + v(Y) + 2Cov(X, Y)$
- $v(X - Y) = v(X) + v(Y) - 2Cov(X, Y)$
- $v(aX + bY) = a^2v(X) + b^2v(Y) + 2ab Cov(X, Y)$
- Si X y Y son independientes, entonces $v(X + Y) = v(X) + v(Y)$
- En general si X_1, X_2, \dots, X_n son variables aleatorias, entonces tenemos que:

$$v\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n v(X_i) + 2 \sum_{i < j} Cov(X_i, X_j)$$

10.6.5. Covarianza

Definición

Sea X, Y dos variables independientes, entonces definimos a la covarianza como:

$$Cov(X, Y) = E((X - \mu_X)(Y - \mu_Y))$$

Es una manera de medir la dispersión conjunta de ambas variables.

Propiedades

- $Cov(X, Y) = E(XY) - \mu_X \mu_Y$
- La covarianza de 2 variables independientes es cero

10.6.6. Momentos Centrales

Si X es una variable aleatoria tal que $E(X) = \mu_x$ entonces tenemos que:

- El k -ésimo momento central esta definida como:

$$\mu_k^c = E[(X - \mu)^k] = \sum_x (x - \mu)^k P(X = x) \quad (10.1)$$

- El k -ésimo momento alrededor del origen esta definida como:

$$\mu_k^0 = E(X^k) = \sum_x x^k P(X = x) \quad (10.2)$$

Función Generadora de Momentos

La podemos definir como:

$$\Psi_X(t) = E(e^{tX}) = \sum_x e^{tx} P(X = x)$$

Solemos decir que la k-ésima derivada de la función generadora de momentos evaluada en $t = 0$ da como resultado el k-ésimo momento central al origen

Es decir, siguen el siguiente patrón:

- $\Psi'_X(t = 0) = E(X)$
- $\Psi''_X(t = 0) = E(X^2)$
- $\Psi'''_X(t = 0) = E(X^3)$
- $\Psi_X^{(n)}(t = 0) = E(X^n)$

Propiedades

- Nota que $\Psi_x(a) = E(e^{aX})$
- Si $Y = aX + b$ entonces tenemos que:
$$\Psi_Y(t) = e^{bt} \Psi_X(at)$$
- $\Psi_X(t = 0) = \mu_k$
- $\Psi_X(t = 0) = E(X)$
- Nota que si tuvieramos un montón de variables aleatorias $X_1, X_2, X_3, \dots, X_n$ Y decimos que $Y = \sum_{i=1}^n X_i$

Entonces tenemos que:

$$\Psi_Y(t) = \prod_{i=1}^n \Psi_{X_i}(t)$$

10.7. Distribuciones Discretas

10.7.1. Bernoulli

Definición

Suponte un experimento en el que solo tienes dos salidas, 0, 1, 0 para el fracaso y 1 para el éxito, suponte que la probabilidad de que salga 1 es p y la que salga 0 es $q = 1 - p$.

Ahora, nuestra variable aleatoria será:

X : Resultado del experimento

Por lo tanto los valores posibles son $X \sim \{0, 1\}$

Solemos entonces escribir esta distribución como:

$$X \sim \text{Ber}(x; p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito

Función Probabilidad

Esta es clásica:

$$f_X(x) = \begin{cases} q & x = 0 \\ p & x = 1 \end{cases}$$

$$= (p^x)((1-p)^{1-x}) = p^x q^{1-x}$$

Función P. Acumulada

Por definición tenemos:

$$F_X(x) = \begin{cases} 0 & x < 0 \\ q & 0 \leq x < 1 \\ p & 1 \leq x \end{cases}$$

Esperanza

Esta es la distribución con la esperanza más fácil que veras:

$$E(X) = p$$

Varianza

Esta es igualmente sencilla:

$$v(X) = p(1-p) = p - p^2 = pq$$

Función Generadora

Esta igual es muy bonita:

$$\Psi(t) = (q) + e^t(p)$$

10.7.2. Binomial

Definición

Un experimento binomial consiste en n ensayos Bernoulli independientes, con una probabilidad de éxito individual constante e igual en todos los experimentos

La variable aleatoria discreta nos medirá el número de éxitos de los experimentos individuales, donde sus posibles valores fueron $X = \{0, 1, \dots, n\}$.

Observa que la variable aleatoria se puede ver como la suma de Bernoullis independientes, es decir $X = X_1 + X_2 + X_3 + \dots + X_n$

Variable Aleatoria

Ahora, nuestra variable aleatoria sera:

X : Número de Éxitos en los experimentos

Ahora, los valores posibles que puede tomar son muy muy sencillos, suponte que haremos n experimentos, entonces X tiene que tomar valores entre $0 \dots n$

Solemos entonces escribir esta distribución como:

$$X \sim \text{Bin}(x; n, p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito de cada experimento Bernoulli

Función Probabilidad

Esta esta fácil:

$$f_X(x) = \binom{n}{x} p^x q^{n-x}$$

Función P. Acumulada

Esta esta fácil:

$$F_X(x) = \sum_{i=0}^x \binom{n}{i} p^i q^{n-i}$$

Esperanza

Esta también es sencilla:

$$E(X) = np$$

Varianza

Esta es bonita también:

$$v(X) = npq$$

Función Generadora

Por definición tenemos que:

$$\Psi(t) = (q + e^t p)^n$$

Propiedades

- Sean X_1, X_2, \dots, X_k k variables aleatorias discretas independientes y $X_i \sim \text{Bin}(x_i; n_i, p)$ con $i = 1, 2, \dots, k$.

Entonces la variable aleatoria $X = X_1 + X_2 + \dots + X_k$ tiene una distribución binomial tal que $X \sim \text{Bin}\left(x; \sum_{i=1}^k n_i, p\right)$

10.7.3. Geométrica

Definición

Supón que se repiten de manera independiente ensayos Bernoulli con una probabilidad de éxito constante de p hasta obtener el primer éxito.

La variable discreta es el número de experimentos hasta un primer éxito, donde sus posibles valores son $X = \{1, 2, 3, \dots\}$.

Variable Aleatoria

Ahora, nuestra variable aleatoria será:

X : Número de experimentos hasta un éxito

Ahora, los valores posibles que puede tomar son muy muy sencillos, porque puede que pase en el primer experimento o en el segundo, es decir la variable aleatoria puede tomar cualquier valor en los enteros positivos.

Solemos entonces escribir esta distribución como:

$$X \sim G(x; p)$$

donde:

- x : Nuestra variable
- p : Probabilidad de Éxito de cada experimento Bernoulli

Función Probabilidad

Esta es fácil:

$$f_X(x) = q^{x-1} p$$

Es decir, es la probabilidad de que todos los anteriores sean fracasos y el actual sea el éxito.

Función P. Acumulada

Esta también es sencilla:

$$F_X(x) = 1 - q^x$$

Esperanza

Esta es muy famosa, y lo repito, que no se te olvide la geométrica

$$E(X) = \frac{1}{p}$$

Varianza

Esta también es sencilla:

$$v(X) = \frac{1-p}{p^2}$$

Función Generadora

Esta también saldrá por definición no somos cobardes:

$$\Psi(t) = \frac{pe^t}{1 - qe^t}$$

Propiedades

- Sea $X \sim G(x; p)$ entonces tenemos que $P(X > a) = q^a$ con a un natural positivo
- Podemos decir que esta distribución no tiene memoria es decir que ya voy a experimentos y no ha pasado nada entonces, debería ya ser más probable que para $a + b$ ya me tocará, me explico mejor ... ¿No? ¡Pues no!

Espera, me explico mejor:

Sea $X \sim G(x; p)$ entonces $P(X > a + b \mid X > a) = P(X > b)$ con a, b un naturales positivos

10.7.4. HiperGeométrica

Definición

Supongamos que tenemos una población de tamaño r , ahora esta particionado de 2 maneras, con elementos del tipo r_1 o r_2 , consideraremos exitosos los elementos de tipo r_1

Ahora vamos a tomar una muestra aleatoria de tamaño n sin reemplazo ni sustitución.

Ahora, solo por notación si es que n , es decir la muestra es menor que nuestra población r la llamamos muestra, pero si $n = r$ entonces decimos que es un censo.

Variable Aleatoria

Ahora, nuestra variable aleatoria sera:

X : Número de elementos del tipo r_1 en una muestra aleatoria de tamaño n

Ahora, los valores posibles que puede tomar son $\max(0, n - r_2) \leq x \leq \min(r_1, n)$

Ahora, ¿Porque esos números tan feos?

Por un lado tenemos que que lo peor que nos puede pasar son dos cosas:

- O bien si el tamaño de tu muestra n es muy pequeña, entonces puedes tener toda la mala suerte del mundo y que pase que todas caigan donde tu no querías por lo tanto, podría pasar que no seleccionará ningún elemento de r_1 entonces $X = 0$.
- Pero, pero que pasaría que tu n fuera lo suficientemente grande tal que incluso si seleccionará todos los que no quería r_2 , aún quedarán elementos por seleccionar, entonces los mínimos elementos r_1 que podría seleccionar es $n - r_2$, entonces $X = n - r_2$

El cálculo para el límite mayor es parecido

- Si tienes que $n \leq r_1$, entonces lo mejor que te puede pasar es que todos caigan donde tu quieras
- Si es que $n > r_1$ entonces puedes seleccionar todos los elementos de r_1

Solemos entonces escribir esta distribución como:

$$X \sim H(x; r_1, r_2, n)$$

donde:

- x : Nuestra variable
- r_1 : Tamaño de nuestra población de interes
- r_2 : Tamaño de la población que no es de interes, sale de $r_2 = r - r_1$
- n : Tamaño de la muestra

Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = \frac{\binom{r_1}{x} \binom{r_2}{n-x}}{\binom{r}{n}}$$

Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^x \binom{r_1}{i} \binom{r_2}{n-i}$$

Esperanza

Esta esta muy interesante:

$$E(X) = n \left(\frac{r_1}{r} \right)$$

Varianza

Esta esta muy difícil, así que se deja para el lector :p

$$v(X) = n \left(\frac{r_1}{r} \right) \left(1 - \frac{r_1}{r} \right) \left(1 - \frac{n-1}{r-1} \right)$$

Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = E(e^{tX}) = \frac{1}{\binom{r}{n}} \sum_{i=\max(0, n-r_2)}^{\min(n, r_1)} e^{ti} \binom{r_1}{i} \binom{r_2}{n-i}$$

Relación con la Binomial

Suponte que tienes una población de r elementos, con r_1 de un tipo “bueno” y $r_2 := n - r$ de un tipo “malo”.

Ahora vamos a tomar una muestra aleatoria de tamaño n , sea entonces X : Número de elementos de tipo bueno en nuestra muestra

ahora podemos tener entonces 2 posibles distribuciones dependiendo de una pregunta clave.

¿Hay reemplazo?

■ Si es que tiene Reemplazo:

Entonces lo que pasa es que la probabilidad de éxito es constante, por lo tanto es simplemente n experimentos de tipo Bernoulli.

La probabilidad de éxito también es bastante sencilla de sacarse, es como $p = \frac{r_1}{r}$

Por lo tanto podemos decir que:

$$X \sim B(x; n, p)$$

Es decir, tendremos (como ya sabemos como se comporta una binomial):

- $E(X) = np = \frac{nr_1}{r}$
- $v(X) = npq = \frac{nr_1}{r} \left(1 - \frac{r_1}{r}\right)$

■ Si es que NO tiene Reemplazo:

Entonces lo que pasa es que la probabilidad de éxito ya no es constante, de hecho, llegamos a la definición de la Hipergeométrica, es decir:

Por lo tanto podemos decir que:

$$X \sim H(x; n, r_1, r_2)$$

Es decir, tendremos (como ya sabemos como se comporta una hipergeométrica):

- $E(X) = np = \frac{nr_1}{r}$
- $v(X) = npq = \frac{nr_1}{r} \left(1 - \frac{r_1}{r}\right) \left(1 - \frac{n-1}{r-1}\right)$

Es decir, sin importar si hay o no reemplazo, el valor esperado es el mismo, pero si es que no hay reemplazos tenemos una varianza es menor.

Podemos también darnos cuenta de que mientras más población la diferencia entre el reemplazo y sin reemplazo cada vez será menor.

10.7.5. Poisson

Variable Aleatoria

La variable aleatoria que cuenta el número de ocurrencias en un periodo de tiempo o espacio físico dado se le llama Poisson.

X : Número de ocurrencias en un periodo de tiempo o espacio dado

Ahora, los valores posibles que puede tomar es $0, 1, 2, \dots$

Solemos entonces escribir esta distribución como:

$$X \sim P(x; \lambda)$$

donde:

- x : Nuestra variable
- λ : Es el número promedio de ocurrencias en el periodo o espacio dado

Relación con la Binomial

Considera $X \sim \text{Bin}(x; n, p)$, entonces cuando más grande sea n más nuestra binomial se va a parecer a una Poisson con $\lambda = np$

Propiedades

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim P(x_i; \lambda_i)$
Entonces $X = \sum_{i=1}^k X_i$ cumple que X se distribuye como una Poisson con parámetro $\lambda = \sum_{i=1}^k \lambda_i$

Función Probabilidad

Esta esta muy interesante, es:

$$f_X(x) = P(X = x) = e^{-\lambda} \frac{\lambda^x}{x!}$$

Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = P(X \leq x) = e^{-\lambda} \sum_{i=0}^x \frac{\lambda^i}{i!}$$

Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = e^{\lambda(e^t - 1)}$$

Esperanza

Esta esta muy interesante:

$$E(X) = \lambda$$

Varianza

Esta esta muy interesante:

$$v(X) = \lambda$$

10.8. Distribuciones Continuas

10.8.1. Uniforme

Definición

La mas sencilla de todas las distribuciones continuas es la uniforme.

Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = \frac{x - a}{b - a}$$

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $a < x < b$.

Solemos entonces escribir esta distribución como:

$$X \sim U(x; a, b)$$

donde:

- a : Inicio de la muestra
- b : Fin de la muestra

Esperanza

Esta esta muy interesante:

$$E(X) = \frac{a + b}{2}$$

Varianza

Esta esta muy difícil, pero si se puede:

$$v(X) = \frac{(a - b)^2}{12}$$

Función Probabilidad

Esto es lo que distingue a una distribución uniforme:

$$f_X(x) = \begin{cases} \frac{1}{b - a} & a < x < b \\ 0 & \text{en otro caso} \end{cases}$$

Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = \frac{e^{bt} - e^{at}}{t(b - a)}$$

10.8.2. Exponencial

Definición

Se utiliza generalmente para representar una distribución del tiempo que transcurre antes de la ocurrencia de un suceso.

Función Generadora

Esta esta muy interesante, es:

$$\Psi_X(t) = \frac{\beta}{\beta - t}$$

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $x > 0$

Solemos entonces escribir esta distribución como:

$$X \sim E(x; \beta)$$

donde:

- β : Es un parámetro que tiene que ser un entero positivo

Esperanza

Esta esta muy interesante:

$$E(X) = \frac{1}{\beta}$$

Varianza

Esta esta muy difícil, pero si se puede:

$$v(X) = \frac{1}{\beta^2}$$

Función Probabilidad

Esto es lo que distingue a una distribución exponencial:

$$f_X(x) = \begin{cases} \beta e^{-\beta x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

Función P. Acumulada

Esta esta muy interesante, es:

$$F_X(x) = 1 - e^{-\beta x}$$

Propiedades

- Podemos decir que esta distribución no tiene memoria, me explico mejor.
Sea $P(X > a + b \mid X > a) = P(X > b)$ con a, b un naturales positivos
- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim E(x_i; \beta)$
Entonces $X = \min(X_1, X_2, \dots, X_k)$ también cumple que X se distribuye como una Exponencial con parámetro $\beta = n\beta$
- Sea $X_1, X_2, \dots, X_\alpha$ variables aleatorias independientes y $X_i \sim E(x_i; \beta)$
Entonces $X = X_1 + X_2 + \dots + X_\alpha$ se destruye como como $X \sim \Gamma(x; \alpha, \beta)$

10.8.3. Gamma

Función Gamma

La función Gamma se puede ver para $a > 0$ como:

$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx$$

Propiedades

La función gamma tiene un par de propiedades interesantes

- $\Gamma(1) = 1$
- $\Gamma(a) = (a-1)\Gamma(a-1)$
- Si $n \in \mathbb{Z}^+$ entonces $\Gamma(n) = (n-1)!$

Definición

Se utiliza generalmente para representar una distribución del tiempo que transcurre antes de la ocurrencia de un suceso.

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria es $x > 0$

Solemos entonces escribir esta distribución como:

$$X \sim \Gamma(x; a, \beta)$$

donde:

- a : Entero positivo
- β : Es un parámetro que tiene que ser un entero positivo

Función Probabilidad

Esto es lo que distingue a una distribución uniforme:

$$f_X(x) = \begin{cases} \frac{\beta^a}{\Gamma(a)} x^{a-1} e^{-\beta x} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

Función Acumulada

Esta esta rara, pero ve que.

$$F_X(x) = 1 - F_X^P(\alpha - 1) \quad \text{Con } \lambda = \beta x$$

Es decir:

$$F_X(x) = 1 - e^{-\beta x} \sum_{i=0}^{\alpha-1} \frac{(\beta x)^i}{i!}$$

Generadora de Momentos

Esto es lo que distingue a una distribución uniforme:

$$\Psi_X(t) = \left(\frac{\beta}{\beta - t} \right)^\alpha$$

Esperanza

Usando la función generadora tenemos que:

$$E(X) = \frac{\alpha}{\beta}$$

Varianza

Usando la función generadora tenemos que:

$$v(X) = \frac{\alpha}{\beta^2}$$

Propiedades

- Si tenemos una distribución Gamma pero donde $\alpha = 1$, entonces lo que en realidad tenemos es una distribución exponencial con la misma β
- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim \Gamma(x_i; \alpha_i, \beta)$
Entonces $X = X_1 + X_2 + \dots + X_k$ se destruye como como $X \sim \Gamma(x; \sum_{i=1}^k \alpha_i, \beta)$

10.8.4. Normal

Definición

Es la más famosa de todas las continuas, es simétrica con respecto al valor central μ

Variable Aleatoria

Ahora, los valores posibles que puede tomar nuestra variable aleatoria son todos los reales

Solemos entonces escribir esta distribución como:

$$X \sim N(x; \mu, \sigma^2)$$

donde:

- μ : El valor central, es cualquier real
- σ^2 : La varianza, es un real positivo

Nota que si pasa que $X \sim N(x; \mu = 0, \sigma^2 = 1)$ entonces se suele denotar como:

$$Z \sim N(0, 1)$$

Se le conoce como normal estandar.

Estandarización

Ya que tenemos una normal estandar, es decir una que cumple que $\mu = 0, \sigma^2 = 1$

Ahora, hay una forma muy facil de “estandarizar” es decir de transformar cualquier punto sobre una normal a ese punto en la estandar esta esta dada por:

$$Z = \frac{X - \mu}{\sigma}$$

Y obviamente tiene su inversa:

$$X = Z\sigma + \mu$$

Función Probabilidad

Esto es lo que distingue a una distribución uniforme:

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

Generadora de Momentos

Esta es sencilla:

$$\Psi_X(t) = e^{t\mu + \frac{1}{2}(t^2\sigma^2)}$$

Media

Mira, que loco :v

$$E(X) = \mu$$

Varianza

Mira, que loco :v

$$v(X) = \sigma^2$$

Propiedades

- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim N(x_i; \mu_i, \sigma_i^2)$
Entonces $X = X_1 + X_2 + \dots + X_k$ se destruye como como $X \sim N(x_i; \sum_{i=1}^k \mu_i, \sum_{i=1}^k \sigma_i^2)$
- Sea $X_i \sim N(x_i; \mu, \sigma^2)$
Entonces $Y = aX + b$ se destruye como como $Y \sim N(y; a\mu + b, a\sigma^2)$
- Sea X_1, X_2, \dots, X_k variables aleatorias independientes y $X_i \sim N(x_i; \mu, \sigma^2)$
Entonces $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ se destruye como como $\bar{X} \sim N(\bar{x}; \mu, \frac{\sigma^2}{n})$

10.9. Probabilidad Hardcore

Teorema Central del Límite

$$\sum_{i=0}^n X_i \approx N(x; \mu_x = n\mu, \sigma_x^2 = n\sigma^2)$$

10.9.1. Definición

Garantiza que para n (tamaño de muestra) suficientemente grande ($n \geq 30$) entonces:

- Si tienes una variable aleatoria que es la media muestral de otras variables aleatorias entonces mientras mas variables aleatorias muestrees entonces más se va aproximar:

$$\bar{X} \approx N(x; \mu = \mu, \sigma^2 = \frac{\sigma^2}{n})$$

- Si tienes una variable aleatoria que esta compuesta por la suma de muchas otras variables aleatorias entonces mientras mas grande sea la cantidad de variables aleatorias más se aproxima a una normal:

Teorema Central de Chebyshev

Definición

Si no se conoce la distribución de la variable aleatoria, pero por circunstancias raras tengamos la media y la varianza entonces podemos conocer información de la variable.

Tenemos que:

$$P(\mu - k\sigma \leq X \leq \mu + k\sigma) \geq 1 - \frac{1}{k^2}$$

$$P(|X - \mu| \leq k\sigma) \geq 1 - \frac{1}{k^2}$$

$$P(|X - \mu| > k\sigma) < \frac{1}{k^2}$$

Bibliografía

- [1] Leticia Cañedo Suárez *Probabilidad*. ESCOM, 2018